

**ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN**



**BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN**

**Ứng dụng mô hình học máy và học sâu trong dự đoán nồng độ và phân loại chất
lượng không khí do ô nhiễm bụi mịn $PM_{2.5}$
Mã số đề tài: SVC2025-174**

**Thuộc nhóm ngành khoa học: Công Nghệ Thông Tin
Chủ nhiệm đề tài: Tiêu Quang Phú
Thành viên tham gia:**

1. Lê Đức Nam
2. Nguyễn Văn Ngàn
3. Phạm Thanh Vương

Giảng viên hướng dẫn: TS Nguyễn Thị Tuyết Nam, Thạc sĩ Nguyễn Trung Tín

Thành phố Hồ Chí Minh, 04/2026

UỶ BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

**Ứng dụng mô hình học máy và học sâu trong dự đoán nồng độ và phân loại chất
lượng không khí do ô nhiễm bụi mịn $PM_{2.5}$**

Mã số đề tài: SVC2025-174

Xác nhận của Khoa
(ký, họ tên)

Giáo viên hướng dẫn
(ký, họ tên)

Chủ nhiệm đề tài
(ký, họ tên)

Thành phố Hồ Chí Minh, 04/2026

TÓM TẮT ĐỀ TÀI

1. Thông tin đề tài

Tên đề tài: “Ứng dụng mô hình học máy và học sâu trong dự đoán nồng độ và phân loại chất lượng không khí do ô nhiễm bụi mịn $PM_{2.5}$ ”

Mã số:

Chủ nhiệm đề tài: Tiêu Quang Phú

Giảng viên hướng dẫn: TS Nguyễn Thị Tuyết Nam, Thạc sĩ Nguyễn Trung Tín

Thời gian thực hiện: Từ tháng 8/2025 đến tháng 4/2026

3. Mục tiêu nghiên cứu

Tìm hiểu và xây dựng mô hình, thuật toán phù hợp để dự đoán được nồng độ và phân loại chất lượng không khí do ô nhiễm bụi mịn $PM_{2.5}$.

Xây dựng mô dự đoán và phân loại chất lượng không khí với độ chính xác cao.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Đề tài tập trung vào việc nghiên cứu, xây dựng và so sánh các mô hình học máy, học sâu để dự báo trực tiếp nồng độ bụi mịn $PM_{2.5}$ theo chuỗi thời gian và phân loại chỉ số chất lượng không khí dựa trên các danh mục.

Phạm vi nghiên cứu: Nghiên cứu sử dụng dữ liệu thời gian và thời tiết tại Thành phố Hồ Chí Minh.

5. Cách tiếp cận và phương pháp nghiên cứu

- Tìm hiểu về các nghiên cứu và kỹ thuật dự báo nồng độ và phân loại AQI bằng học máy và học sâu bằng các mô hình phù hợp. Đồng thời tham khảo các tiêu chuẩn đánh giá phù hợp và bài toán phân loại nhằm xây dựng cơ sở lý thuyết vững chắc cho việc triển khai.
- Thu thập các tài liệu, bài báo, dữ liệu cần để thực hiện xây dựng mô hình.
- Dữ liệu được sử dụng bao gồm độ bụi mịn $PM_{2.5}$ theo giờ, các giá trị AQI và các yếu tố đầu vào như năm, tháng, ngày, giờ, nhiệt độ, độ ẩm, tốc độ gió, hướng gió, lượng mưa cùng các biến thời gian liên quan được thu thập từ năm 2018 đến 2023 ở thành phố Hồ Chí Minh.

6. Ý nghĩa thực tiễn của đề tài

- Nghiên cứu giúp việc có thể đưa ra các đoán về chất lượng không khí từ đó đưa ra các cảnh báo kịp thời cho cộng đồng.
- Kết quả nghiên cứu góp phần tạo điều kiện giảm thiểu thiệt hại kinh tế từ ô nhiễm từ đó đưa ra các giải pháp phù hợp để phát triển, đánh giá chính xác tác động của PM_{2.5} đến sức khoẻ con người.

7. Bố cục của đề tài

Chương I: Bối cảnh, tính cấp thiết đề tài và các hướng tiếp cận trong quá trình nghiên cứu.

Chương II: Nêu các khái niệm về thuật ngữ chuyên ngành, giới thiệu các mô hình, các thuật toán có liên quan trong đề tài nghiên cứu.

Chương III: Đề xuất mô hình, kỹ thuật sẽ sử dụng trong đề tài nghiên cứu.

Chương IV: Thu thập tập dữ liệu, chạy các mô hình, báo cáo và so sánh kết quả

Chương V: Kết luận, kiến nghị và định hướng nghiên cứu trong tương lai.

MỤC LỤC

CHƯƠNG I: GIỚI THIỆU	1
1.1 Bối cảnh thực tế hiện nay	1
1.2 Mục tiêu đề tài	2
1.3 Các hướng tiếp cận	2
1.3.1 Các công trình nghiên cứu liên quan	2
1.3.2 Hướng tiếp cận đề xuất	4
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	5
2.1 Ô nhiễm không khí	5
2.1.1 Bụi mịn PM _{2.5}	5
2.1.2 Nồng độ PM _{2.5} ở thành phố Hồ Chí Minh	6
2.1.3 Chất lượng không khí AQI	7
2.2 Các mô hình học máy và học sâu	10
2.2.1 RandomForestRegressor	10
2.2.2 SVR	10
2.2.3 LinearRegression	11
2.2.4 Mô hình CNN (Convolutional Neural Network)	11
2.2.5 Mô hình LSTM (Long Short-Term Memory)	12
2.2.6 Mô hình Transformer	14
2.3 Mô hình Chỉ số đánh giá	15
2.3.1 Bài toán hồi quy	15
2.3.2 Bài toán phân loại	16
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ XUẤT	18
3.1. Tổng quan Mô hình Đề xuất và Định hướng Tiếp cận	18
3.2. Mô tả và Tiền xử lý Dữ liệu Khí tượng	23
3.2.1 Mô tả dữ liệu đầu vào	23
3.2.2. Xử lý giá trị khuyết và chuẩn hoá dữ liệu	24
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	26
4.1. Mô tả tập dữ liệu thực nghiệm	26
4.1.1. Phân chia tập dữ liệu (Data Splitting)	26
4.1.2. Đặc trưng dữ liệu và phân tích tương quan	27
4.1.3. Phân tích xu hướng và tính chu kỳ	28
4.2. Thiết lập Thực nghiệm và Chỉ số Đánh giá	28
4.2.1. Cấu hình thực nghiệm và Siêu tham số (Hyperparameters)	28
4.2.2. Chỉ số đánh giá mô hình Hồi quy	29

4.2.3. Chỉ số đánh giá bài toán Phân loại (AQI).....	29
4.3. Phân tích Kết quả Dự báo hồi quy $PM_{2.5}$	30
4.4. Phân tích kết quả phân loại AQI và đánh giá sai số	33
4.4.1 Kết quả của từng mô hình.....	33
4.4.2 Phân tích và đánh giá.....	49
CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ.....	52
5.1. Kết luận	52
5.2. Hạn chế của nghiên cứu.....	53
5.3. Hướng phát triển trong tương lai	53
TÀI LIỆU THAM KHẢO	54

DANH MỤC HÌNH

Hình 1: Kích thước của hạt bụi mịn	6
Hình 2: Time series of $PM_{2.5}$ levels in HCM (2017-2024)	7
Hình 3: Thang đo chỉ số AQI	8
Hình 4: Các trạm quan trắc ở TPHCM.....	9
Hình 5: Phép toán tích chập một chiều (1D).....	12
Hình 6: Sơ đồ cấu trúc Long Short-Term Memory	12
Hình 7: Sơ đồ kiến trúc mô hình Transformer	15
Hình 8: Ma trận tương quan giữa các biến (Heatmap)	27
Hình 9: Kết quả dự đoán mô hình CNN_LSTM 6 tiếng	34
Hình 10: Kết quả dự đoán mô hình CNN_LSTM 12 tiếng	37
Hình 11: Kết quả dự đoán mô hình CNN_LSTM 24 tiếng	40
Hình 12: Kết quả dự đoán mô hình Transformer 6 tiếng.....	43
Hình 13: Kết quả dự đoán mô hình Transformer 12 tiếng.....	45
Hình 14: Kết quả dự đoán mô hình Transformer 24 tiếng.....	48

DANH MỤC BẢNG

<i>Bảng 1: Kết quả dự báo tại mốc 6 giờ</i>	<i>30</i>
<i>Bảng 2: Kết quả dự báo tại mốc 12 giờ</i>	<i>31</i>
<i>Bảng 3 Kết quả dự báo tại mốc 24 giờ.....</i>	<i>31</i>
<i>Bảng 4: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 6 tiếng</i>	<i>33</i>
<i>Bảng 5: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 12 tiếng</i>	<i>35</i>
<i>Bảng 6: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 24 tiếng</i>	<i>38</i>
<i>Bảng 7: Báo cáo phân loại chỉ số AQI mô hình Transformer 6 tiếng.....</i>	<i>41</i>
<i>Bảng 8: Báo cáo phân loại chỉ số AQI mô hình Transformer 12 tiếng.....</i>	<i>44</i>
<i>Bảng 9: Báo cáo phân loại chỉ số AQI mô hình Transformer 24 tiếng.....</i>	<i>46</i>
<i>Bảng 10: So sánh hiệu suất giữa hai mô hình.....</i>	<i>50</i>

CHƯƠNG I: GIỚI THIỆU

1.1 Bối cảnh thực tế hiện nay

Trong bối cảnh hiện nay, cùng với sự phát triển mạnh mẽ của quá trình đô thị hóa và công nghiệp hóa, các thành phố lớn trên thế giới đang phải đối mặt với nhiều vấn đề môi trường nghiêm trọng, trong đó ô nhiễm không khí là một trong những thách thức lớn nhất. Đặc biệt, tại các đô thị đông dân như Thành phố Hồ Chí Minh, sự gia tăng nhanh chóng của phương tiện giao thông, hoạt động xây dựng và sản xuất công nghiệp đã góp phần làm suy giảm chất lượng không khí một cách đáng kể [1].

Một trong những tác nhân gây ô nhiễm nguy hiểm nhất là bụi mịn $PM_{2.5}$ – các hạt vật chất có đường kính nhỏ hơn 2.5 micromet. Do kích thước siêu nhỏ, $PM_{2.5}$ có khả năng lơ lửng trong không khí trong thời gian dài và dễ dàng xâm nhập sâu vào hệ hô hấp của con người. Các nghiên cứu đã chỉ ra rằng việc tiếp xúc lâu dài với $PM_{2.5}$ có thể gây ra nhiều bệnh lý nghiêm trọng như hen suyễn, bệnh tim mạch, ung thư phổi và các bệnh về đường hô hấp mãn tính [2].

Trong thực tế, chất lượng không khí không chỉ ảnh hưởng đến sức khỏe cộng đồng mà còn tác động trực tiếp đến chất lượng cuộc sống, năng suất lao động và sự phát triển bền vững của xã hội. Chính vì vậy, việc theo dõi, đánh giá và đặc biệt là dự đoán nồng độ $PM_{2.5}$ trở thành một yêu cầu cấp thiết.

Hiện nay, người dân có xu hướng sử dụng các ứng dụng hoặc nền tảng trực tuyến để cập nhật tình trạng ô nhiễm không khí theo thời gian thực. Tuy nhiên, các hệ thống này chủ yếu cung cấp dữ liệu hiện tại hoặc dự báo ngắn hạn với độ chính xác chưa cao. Điều này đặt ra nhu cầu phát triển các mô hình dự đoán thông minh, có khả năng khai thác hiệu quả dữ liệu lịch sử và các yếu tố khí tượng để đưa ra dự báo chính xác hơn.

Đặc biệt, trong điều kiện khí hậu nhiệt đới gió mùa như tại Thành phố Hồ Chí Minh, các yếu tố như lượng mưa, nhiệt độ, tốc độ gió và hướng gió có ảnh hưởng đáng kể đến sự biến động của $PM_{2.5}$. Ví dụ, trong mùa mưa, các hạt bụi có xu hướng bị “rửa trôi” bởi mưa, làm giảm nồng độ trong không khí; trong khi đó, vào mùa khô, tình trạng ô nhiễm thường nghiêm trọng hơn do thiếu các yếu tố làm sạch tự nhiên.

Do đó, việc nghiên cứu và xây dựng các mô hình dự đoán $PM_{2.5}$ phù hợp với điều kiện đặc thù của Việt Nam là một hướng đi cần thiết và có ý nghĩa thực tiễn cao.

1.2 Mục tiêu đề tài

Bài toán dự đoán nồng độ $PM_{2.5}$ thuộc nhóm bài toán dự báo chuỗi thời gian đa biến (multivariate time-series forecasting), trong đó dữ liệu đầu vào bao gồm cả giá trị $PM_{2.5}$ trong quá khứ và các yếu tố khí tượng liên quan.

Mục tiêu chính của đề tài là xây dựng một mô hình có khả năng:

- Dự đoán chính xác nồng độ $PM_{2.5}$ theo thời gian
- Khai thác hiệu quả mối quan hệ giữa $PM_{2.5}$ và các yếu tố khí tượng
- Cải thiện hiệu suất so với các mô hình truyền thống

Cụ thể, đề tài tập trung vào các mục tiêu sau:

- Phân tích sự biến động của $PM_{2.5}$ theo thời gian tại TP.HCM trong giai đoạn 2018–2023
- Xác định mối tương quan giữa $PM_{2.5}$ và các yếu tố khí tượng như nhiệt độ, lượng mưa, tốc độ gió
- Xây dựng mô hình học sâu kết hợp BiLSTM và Attention Mechanism để dự đoán $PM_{2.5}$
- Tối ưu hóa độ dài chuỗi đầu vào (time lag) nhằm đạt hiệu suất tốt nhất
- Đánh giá mô hình thông qua các chỉ số như R^2 , MAE và RMSE

Bên cạnh đó, đề tài còn dự đoán tình trạng không khí thông qua các chỉ số AQI để dự báo chất lượng không khí cho các ngày tiếp theo. Đây là một tính mới trong đề tài lần này.

1.3 Các hướng tiếp cận

1.3.1 Các công trình nghiên cứu liên quan

Bài toán dự đoán $PM_{2.5}$ đã được nghiên cứu rộng rãi trong nhiều năm qua với nhiều hướng tiếp cận khác nhau, từ các mô hình truyền thống đến các phương pháp học máy và học sâu hiện đại.

Các nghiên cứu ban đầu chủ yếu sử dụng các phương pháp thống kê và xử lý tín hiệu như:

- ARIMA, SARIMA (mô hình chuỗi thời gian)
- Phân tích tương quan và hồi quy tuyến tính

Tuy nhiên, các phương pháp này gặp hạn chế khi xử lý dữ liệu phi tuyến và đa biến [3].

Sau đó, các mô hình học máy (Machine Learning) như:

- Support Vector Regression (SVR)
- Random Forest (RF)
- XGBoost
- K-Nearest Neighbors (KNN)

đã được áp dụng và cho kết quả tốt hơn nhờ khả năng học từ dữ liệu lớn và khai thác nhiều đặc trưng đầu vào [4].

Gần đây, các mô hình học sâu (Deep Learning) đã trở thành xu hướng chủ đạo trong bài toán dự đoán $PM_{2.5}$, đặc biệt là:

- LSTM (Long Short-Term Memory)
- BiLSTM (Bidirectional LSTM)
- DNN (Deep Neural Network)

Các mô hình này có khả năng học được các phụ thuộc dài hạn trong dữ liệu chuỗi thời gian, giúp cải thiện đáng kể độ chính xác dự đoán [5].

Ngoài ra, các mô hình lai như CNN-LSTM hoặc CNN-BiLSTM cũng được đề xuất nhằm kết hợp khả năng trích xuất đặc trưng của CNN với khả năng xử lý chuỗi của LSTM.

Một hướng tiếp cận mới và hiệu quả là tích hợp Attention Mechanism vào các mô hình học sâu. Cơ chế attention cho phép mô hình tập trung vào các đặc trưng quan trọng nhất trong dữ liệu đầu vào, từ đó cải thiện hiệu suất và khả năng giải thích.

1.3.2 Hướng tiếp cận đề xuất

Trong đề tài này, chúng tôi đề xuất một phương pháp dự đoán nồng độ $PM_{2.5}$ dựa trên mô hình học sâu kết hợp giữa BiLSTM và Attention Mechanism.

Đầu tiên, dữ liệu đầu vào bao gồm:

- Nồng độ $PM_{2.5}$ trong quá khứ
- Các thông số khí tượng như nhiệt độ, lượng mưa, tốc độ gió và hướng gió

Tương tự như kỹ thuật cửa sổ trượt trong xử lý tín hiệu, chúng tôi áp dụng phương pháp chia dữ liệu theo các khoảng thời gian cố định (time lag) như 2 giờ, 6 giờ, 12 giờ, 24 giờ,... để tạo thành các chuỗi đầu vào cho mô hình. Việc này giúp mô hình học được sự phụ thuộc theo thời gian của $PM_{2.5}$.

Sau đó, mô hình BiLSTM được sử dụng để xử lý dữ liệu chuỗi theo cả hai chiều thời gian, giúp khai thác tối đa thông tin từ dữ liệu quá khứ. Trên nền tảng đó, Attention Mechanism được tích hợp nhằm xác định và tập trung vào những thời điểm hoặc đặc trưng có ảnh hưởng lớn nhất đến kết quả dự đoán.

Cuối cùng, đầu ra của mô hình sẽ là giá trị dự đoán nồng độ $PM_{2.5}$ tại thời điểm tiếp theo.

Để đánh giá hiệu quả của mô hình, chúng tôi sử dụng các chỉ số như sau:

- Hệ số xác định (R^2)
- Sai số tuyệt đối trung bình (MAE)
- Căn sai số bình phương trung bình (RMSE)

Ngoài ra, trong đề tài lần này chúng tôi còn làm thêm bài toán phân loại chỉ số AQI dựa vào các mô hình dự đoán chỉ số AQI được trình bày dưới dạng Classification Report. Các chỉ số chính được sử dụng để đánh giá hiệu suất mô hình bao gồm Precision, Recall, F1-score, Accuracy, cùng với các giá trị trung bình Macro avg và Weighted avg.


CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Ô nhiễm không khí

Ô nhiễm không khí là mối đe dọa đối với sự phát triển bền vững của các quốc gia và cộng đồng trên toàn thế giới nói chung và châu Á nói riêng [6]. Ô nhiễm không khí được định nghĩa là sự hiện diện của một hoặc nhiều chất gây ô nhiễm trong khí quyển (trong nhà và ngoài trời), chẳng hạn như bụi mịn, khói, khí, sương mù, mùi hôi, khói hoặc hơi nước với số lượng, đặc điểm và thời gian ảnh hưởng đến sinh vật sống [7]. Không khí sạch rất quan trọng để duy trì sự sống và sức khỏe con người. Nó đảm bảo chức năng hô hấp bình thường, cung cấp oxy cần thiết và giảm nguy cơ mắc các bệnh mãn tính và cấp tính. Ô nhiễm không khí, đặc biệt là bụi mịn PM_{2.5}, là một vấn đề toàn cầu nghiêm trọng ảnh hưởng đến sức khỏe con người, với các nghiên cứu cho thấy hơn 90% dân số thế giới tiếp xúc với mức độ PM_{2.5} không an toàn [8]. Ô nhiễm không khí đã trở thành một vấn đề rất nghiêm trọng đối với tất cả các quốc gia. Nó âm thầm ảnh hưởng đến sức khỏe của chúng ta, bao gồm cả sự gia tăng các bệnh liên quan trực tiếp đến chức năng hô hấp cũng như hệ tim mạch và hệ thần kinh trung ương, đặc biệt là não bộ và biểu hiện gen [9], [10].

2.1.1 Bụi mịn PM_{2.5}

Bụi mịn (PM) là một hỗn hợp phức tạp của các hạt nhỏ và giọt chất lỏng, bao gồm axit, hợp chất hữu cơ, kim loại và các hạt đất hoặc bụi. PM được phân loại theo kích thước hạt: PM₁₀ bao gồm các hạt nhỏ hơn 10 μm , PM_{2.5} bao gồm các hạt nhỏ hơn 2,5 μm và các hạt siêu mịn nhỏ hơn 0,1 μm . Kích thước của bụi mịn (PM) có liên quan mật thiết đến tác động của nó đối với sức khỏe, với các hạt nhỏ hơn gây hại nhiều hơn. Do đó, PM_{2.5} gây ra rủi ro sức khỏe lớn hơn PM₁₀ do khả năng thâm nhập sâu hơn vào cơ thể [11]. Theo một nghiên cứu của Lelieveld, ô nhiễm không khí ngoài trời, chủ yếu là PM_{2.5}, gây ra 3,3 triệu ca tử vong mỗi năm trên toàn thế giới, chủ yếu ở châu Á, với tỷ lệ tử vong có thể tăng gấp đôi vào năm 2050 [12].




Hình 1: Kích thước của hạt bụi mịn

Nguyên nhân sinh ra bụi mịn có thể kể đến các hoạt động sinh hoạt trong đời sống như:

- Giao thông vận tải: Các phương tiện giao thông sản sinh ra lượng khói thải, cát bụi trong quá trình di chuyển và bào mòn mặt đường từ đó sinh ra bụi mịn.
- Sinh hoạt: Sử dụng bếp than, bếp củi cũng sẽ sinh ra lượng khói thải.
- Sản xuất công nghiệp: Các xưởng, nhà máy sản xuất thải ra một lượng khói lớn ra môi trường, không khí làm tăng lượng bụi mịn trong không khí.
- Xây dựng: Xây dựng cầu đường, chung cư, cao ốc cũng là một phần nguyên nhân gây ra lượng lớn bụi mịn.

2.1.2 Nồng độ PM_{2.5} ở thành phố Hồ Chí Minh

Theo một nghiên cứu của WHO, tại Việt Nam, mỗi năm có hơn 60.000 ca tử vong liên quan đến ô nhiễm không khí [13]. Thành phố Hồ Chí Minh, một siêu đô thị rộng lớn với diện tích 2.095 km² và dân số 9,5 triệu người tính đến năm 2024, đã trải qua sự tăng trưởng nhanh chóng trong các ngành công nghiệp, hoạt động xuất khẩu, du lịch và dịch vụ, dẫn đến những thách thức đáng kể về ô nhiễm môi trường. Từ tháng 3 năm 2017 đến tháng 3 năm 2018, nồng độ PM_{2.5} được ghi nhận dao động từ 10,4 đến 110,8 $\mu\text{g m}^{-3}$ mỗi giờ, với mức trung bình hàng năm là $36,3 \pm 13,7 \mu\text{g m}^{-3}$. Các mức này liên tục vượt quá tiêu chuẩn chất lượng không khí của Việt Nam là $25 \mu\text{g m}^{-3}$ và hướng dẫn của Tổ chức Y tế Thế giới là $10 \mu\text{g m}^{-3}$, gây ra rủi ro sức khỏe đáng kể tại các khu vực được giám sát.



Hình 2: Time series of $PM_{2.5}$ levels in HCM (2017-2024)

Mặc dù có sự khác biệt về mức độ phơi nhiễm giữa các địa điểm lấy mẫu, nồng độ $PM_{2.5}$ vẫn cho thấy mối tương quan mạnh mẽ và sự khác biệt tối thiểu [14]. Phơi nhiễm với nồng độ $PM_{2.5}$ cao ảnh hưởng xấu đến sức khỏe con người, đặc biệt là trẻ em, dẫn đến các bệnh về đường hô hấp [2]. Do đó, việc dự báo mức độ $PM_{2.5}$ để đưa ra cảnh báo và giảm thiểu rủi ro phơi nhiễm là vô cùng quan trọng.

2.1.3 Chất lượng không khí AQI


Chỉ số AQI (Air Quality Index) – hay còn gọi là chỉ số chất lượng không khí – là công cụ quan trọng dùng để đánh giá mức độ ô nhiễm không khí tại một khu vực cụ thể vào thời điểm nhất định.

AQI được tính toán dựa trên nồng độ trung bình của một số chất ô nhiễm chính trong không khí, bao gồm bụi mịn $PM_{2.5}$, bụi thô PM_{10} , ôzôn (O_3), cacbon monoxide (CO), lưu huỳnh điôxít (SO_2) và nitơ điôxít (NO_2).

PM2.5 µg/m3	PM10 µg/m3	Cảnh báo	Màu RBG	Ghi chú
0.0-12.0	0-54	Tốt	0;228;0	Chất lượng không khí tốt và gây ra ít hoặc không rủi ro tới sức khỏe con người.
12.1-35.4	55-154	Trung bình	255;255;0	Những người nhạy cảm nên tránh hoạt động ngoài trời vì họ có thể gặp các triệu chứng về hô hấp.
35-55.4	155-254	Ảnh hưởng xấu đến nhóm nhạy cảm	255;126;0	Mọi người, đặc biệt là những người nhạy cảm, có nguy cơ gặp phải các vấn đề về dị ứng và hô hấp
55.5-150.4	255-354	Ảnh hưởng xấu đến sức khỏe	255;0;0	Tăng khả năng tác động xấu và trầm trọng hơn cho tim và phổi của con người.
150.5-250.4	355-424	Ảnh hưởng rất xấu đến sức khỏe	143;63;151	Sức khỏe mọi người sẽ bị ảnh hưởng đáng kể. Những người nhạy cảm nên hạn chế các hoạt động ngoài trời.
>250.5	>425	Nguy hiểm	126;0;35	Mọi người có nguy cơ cao gặp phải các tác động xấu về sức khỏe và dị ứng nghiêm trọng. Mọi người nên tránh các hoạt động ngoài trời

Hình 3: Thang đo chỉ số AQI

Chỉ số này được biểu diễn trên thang điểm từ 0 đến 500. Giá trị càng cao thì mức độ ô nhiễm càng nghiêm trọng và nguy cơ ảnh hưởng đến sức khỏe con người càng lớn. Thang AQI được chia thành nhiều cấp độ khác nhau, mỗi cấp được gắn với một màu sắc cụ thể (xanh, vàng, cam, đỏ, tím, nâu đỏ...) nhằm giúp người dân dễ dàng nhận biết tình trạng không khí và chủ động áp dụng các biện pháp bảo vệ sức khỏe phù hợp.



Hình 4: Các trạm quan trắc ở TPHCM

Dựa trên dữ liệu từ trang web IQAir, chúng ta có thể quan sát chỉ số PM_{2.5} trung bình đo được và vị trí các trạm quan trắc tại Thành phố Hồ Chí Minh (Hình 4).

Tại Thành phố Hồ Chí Minh, phần lớn các báo cáo về PM_{2.5} được lấy từ dữ liệu quan trắc thời gian thực, chỉ có một số ít nghiên cứu tập trung vào dự báo mức độ PM_{2.5}. Nghiên cứu về dự báo nồng độ PM_{2.5} vẫn còn hạn chế, và thiếu thông tin đầy đủ để cảnh báo người dân về nguy cơ ô nhiễm PM_{2.5}. Trong bối cảnh tình hình ô nhiễm không khí ngày càng phức tạp tại các khu vực đô thị lớn như Thành phố Hồ Chí Minh, nhu cầu dự báo nồng độ PM_{2.5} chính xác, theo thời gian trở nên cấp thiết. Dự báo mức độ PM_{2.5} không chỉ giúp người dân chủ động bảo vệ sức khỏe mà còn hỗ trợ chính quyền xây dựng các chính sách kiểm soát chất lượng không khí.

2.2 Các mô hình học máy và học sâu

2.2.1 RandomForestRegressor

RandomForestRegressor (RF), được giới thiệu bởi L. Breiman [15], là một kỹ thuật học máy tận dụng học tập tập hợp bằng cách tích hợp nhiều cây quyết định, mỗi cây được xây dựng bằng thuật toán Classification and Regression Tree (CART). Trong RF, các cây được xây dựng thông qua sự kết hợp giữa lấy mẫu bootstrap, lựa chọn đặc trưng ngẫu nhiên và bỏ phiếu đa số (hoặc trung bình), tạo ra một tập hợp các cây quyết định mạnh mẽ và đa dạng [16]. Chiến lược kết hợp này quản lý hiệu quả các tập dữ liệu phức tạp và giảm thiểu rủi ro quá khớp liên quan đến các cây quyết định riêng lẻ. Tổng số tham số trong mô hình RF có thể được ước tính bằng cách nhân số lượng cây với số tham số trên mỗi cây [17]. RF đảm bảo phân bố dữ liệu đồng đều trong các vùng bằng cách phân chia không gian biến thành các không gian con nhỏ hơn [15]. Kết hợp RF với lấy mẫu lại bootstrap giúp tăng cường hiệu suất, vì phương pháp này lấy k mẫu ngẫu nhiên (có hoàn trả) từ dữ liệu huấn luyện, cân bằng sự đại diện cho các lớp ít được đại diện. RF hoạt động bằng cách tổng hợp các dự đoán từ nhiều cây quyết định, chọn lớp đa số làm đầu ra cuối cùng. Việc áp dụng rộng rãi nó trong nghiên cứu và công nghiệp xuất phát từ việc giảm lỗi đáng kể đạt được bằng cách dựa vào quyết định tập thể của nhiều cây thay vì chỉ một cây duy nhất.

2.2.2 SVR

Hồi quy vector hỗ trợ (SVR) tìm cách xác định một siêu mặt phẳng trong không gian đặc trưng nắm bắt tối ưu mối quan hệ giữa các biến đầu vào và các giá trị mục tiêu tương ứng của chúng. Siêu mặt phẳng này được xác định bởi một tập hợp con các điểm dữ liệu quan trọng, được gọi là vectơ hỗ trợ, đóng vai trò quan trọng trong việc xác định vị trí và hướng của nó [18]. Hồi quy vectơ hỗ trợ (SVR) thường được sử dụng trong các nhiệm vụ dự báo chuỗi thời gian và ban đầu được coi là một phương pháp đổi mới do việc sử dụng truyền thống của nó trong việc xác định các ranh giới phi tuyến tính thông qua các hàm nhân [19].

Trong dự báo, SVR được huấn luyện độc lập trên dữ liệu huấn luyện giống hệt nhau với các giá trị mục tiêu khác nhau, cho phép nó học các hàm tuyến tính hoặc phi tuyến tính, thường được gọi là hàm nhân [20]. Hàm đã học này sau đó được áp dụng để đưa ra dự đoán, thường được đánh giá bằng các chỉ số như RMSE hoặc MAE.

2.2.3 LinearRegression


Hồi quy tuyến tính là một phương pháp thống kê để mô hình hóa mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập. Mô hình được huấn luyện bằng cách giảm thiểu khoảng cách vuông góc trung bình từ hàm dự đoán (một đường thẳng hoặc mặt phẳng) đến các giá trị mục tiêu trong dữ liệu huấn luyện. Quá trình này tạo ra đường thẳng hoặc mặt phẳng phù hợp nhất, trong nghiên cứu này, được sử dụng để dự báo nồng độ $PM_{2.5}$ trong tương lai bằng cách sử dụng thời gian làm biến độc lập. Hồi quy tuyến tính được áp dụng rộng rãi trong nhiều lĩnh vực khác nhau cho mô hình dự đoán, phân tích mối quan hệ và dự báo [21].

2.2.4 Mô hình CNN (Convolutional Neural Network)

Hoạt động tích chập một chiều (1D convolution) được minh họa trong Hình 5. Sự khác biệt giữa CNN và MLP là CNN sử dụng khái niệm chia sẻ trọng số (weight sharing). Trong Hình 3, x1 đến x6 là các giá trị đầu vào, và c1 đến c4 là các bản đồ đặc trưng sau khi thực hiện tích chập 1D [22].

Những gì kết nối giữa lớp đầu vào và lớp tích chập là các kết nối màu đỏ, xanh dương và xanh lá. Mỗi kết nối có giá trị trọng số riêng của nó, và các kết nối cùng màu sẽ có cùng một giá trị trọng số. Do đó, trong Hình 3, chỉ cần 3 giá trị trọng số là đủ để thực hiện phép tích chập.


Ưu điểm của CNN là quá trình huấn luyện tương đối dễ dàng hơn vì số lượng trọng số ít hơn nhiều so với kiến trúc kết nối đầy đủ (fully-connected). Hơn nữa, các đặc trưng quan trọng có thể được trích xuất một cách hiệu quả [22].



Hình 5: Phép toán tích chập một chiều (1D)

2.2.5 Mô hình LSTM (Long Short-Term Memory)

LSTM là một trong những mô hình thuộc họ RNN. Sơ đồ cấu trúc của LSTM được minh họa trong Hình 6, trong đó σ biểu thị hàm sigmoid, như được thể hiện ở Phương trình (1). LSTM bao gồm ba cổng chính: cổng vào, cổng ra và cổng quên. Sự tương tác giữa ba cổng này giúp LSTM có khả năng giải quyết tốt vấn đề phụ thuộc dài hạn mà các mạng RNN thông thường không thể học được [22].



Hình 6: Sơ đồ cấu trúc Long Short-Term Memory

Ngoài ra, một vấn đề phổ biến trong các mạng nơ-ron sâu là hiện tượng gradient biến mất, nghĩa là tốc độ học của các lớp ẩn phía trước chậm hơn so với các lớp ẩn sâu hơn. Hiện tượng này thậm chí có thể làm giảm độ chính xác khi số lượng lớp ẩn tăng lên.

Tuy nhiên, nhờ thiết kế thông minh của ô nhớ trong LSTM, mô hình có thể khắc phục hiệu quả vấn đề gradient biến mất trong quá trình lan truyền ngược và có khả năng học được các chuỗi đầu vào với số bước thời gian dài hơn. Do đó, LSTM thường được sử dụng để giải quyết các bài toán liên quan đến dữ liệu chuỗi thời gian [22].

Các công thức dẫn xuất cụ thể của LSTM được trình bày chi tiết từ Phương trình (2) đến Phương trình (11).

$$\text{sigmoid}(x) = \frac{1}{1+e^{-x}} \quad (1)$$

$$\bar{z}^t = W_z x^t + R_z y^{t-1} + b_z \quad (2)$$

$$z^t = \tanh(\bar{z}^t) \quad (3)$$

$$\bar{i}^t = W_i x^t + R_i y^{t-1} + p_i \odot c^{t-1} + b_i \quad (4)$$

$$i^t = \text{sigmoid}(\bar{i}^t) \quad (5)$$

$$\bar{f}^t = W_f x^t + R_f y^{t-1} + p_f \odot c^{t-1} + b_f \quad (6)$$

$$f^t = \text{sigmoid}(\bar{f}^t) \quad (7)$$

$$c^t = z^t \odot i^t + c^{t-1} \odot f^t \quad (8)$$

$$\bar{o}^t = W_o x^t + R_o y^{t-1} + p_o \odot c^{t-1} + b_o \quad (9)$$

$$o^t = \text{sigmoid}(\bar{o}^t) \quad (10)$$

$$y^t = \tanh(c^t) \odot o^t \quad (11)$$

Trong đó, W_z, W_i, W_f, W_o là các trọng số đầu vào (input weights); R_z, R_i, R_f, R_o là các trọng số hồi tiếp (recurrent weights); p_i, p_f, p_o là các trọng số peephole; b_z, b_i, b_f, b_o là các trọng số bias (bias weights).


- z^t là đầu vào khối (block input)
- f^t là cổng quên (forget gate)
- c^t là ô nhớ (cell state)
- o^t là cổng đầu ra (output gate)
- y^t là đầu ra của khối (block output)
- Ký hiệu $\odot$ biểu thị phép nhân từng phần tử (point-wise multiplication)

Để đạt được mục tiêu tối ưu hóa tham số, cả CNN lẫn LSTM đều có thể sử dụng thuật toán lan truyền ngược để điều chỉnh các tham số của mô hình trong quá trình huấn luyện.

2.2.6 Mô hình Transformer

Mô hình Transformer đã cách mạng hóa nhiều lĩnh vực của học máy, bao gồm xử lý ngôn ngữ tự nhiên và dự báo chuỗi thời gian. Trong bối cảnh dự báo nồng độ $PM_{2.5}$, khả năng nắm bắt các phụ thuộc dài hạn và các mô hình thời gian phức tạp của mô hình Transformer khiến nó trở thành một công cụ mạnh mẽ để dự báo mức độ ô nhiễm không khí [23].

Các phương pháp truyền thống thường gặp khó khăn với bản chất phi tuyến tính và động của dữ liệu $PM_{2.5}$. Tuy nhiên, cơ chế tự chú ý của Transformer cho phép mô hình đánh giá mức độ quan trọng của các bước thời gian khác nhau một cách hiệu quả, từ đó dẫn đến các dự báo chính xác và vững chắc hơn. Sơ đồ kiến trúc của mô hình Transformer được thể hiện trong hình 7 [23].



Hình 7: Sơ đồ kiến trúc mô hình Transformer

2.3 Mô hình Chỉ số đánh giá

2.3.1 Bài toán hồi quy

Để đánh giá hiệu suất của các phương pháp khác nhau trong nhiệm vụ dự báo chất lượng không khí, ba chỉ số đánh giá điển hình, bao gồm sai số bình phương trung bình gốc (RMSE), sai số tuyệt đối trung bình (MAE) và hệ số xác định (R^2), đã được sử dụng trong các thí nghiệm. Ba chỉ số đánh giá này được trình bày dưới đây.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (14)$$

Trong đó, biểu thị giá trị $PM_{2.5}$ quan sát được của mẫu thứ biểu thị giá trị $PM_{2.5}$ dự đoán được của mẫu thứ là giá trị trung bình của các giá trị $PM_{2.5}$ quan sát được, và là tổng số mẫu. RMSE và MAE càng nhỏ thì hiệu suất dự đoán cuối cùng càng tốt, R^2 thường tương đối lớn hơn.

2.3.2 Bài toán phân loại

Kết quả đánh giá mô hình dự đoán chỉ số AQI được trình bày dưới dạng Classification Report. Các chỉ số chính được sử dụng để đánh giá hiệu suất mô hình bao gồm Precision, Recall, F1-score, Accuracy, cùng với các giá trị trung bình Macro avg và Weighted avg.

- Precision (độ chính xác): tỷ lệ dự đoán dương đúng.
 - Công thức: $\text{precision} = TP / (TP + FP)$ (15)
 - Trong đó TP là số True Positive (dự đoán đúng), FP là số False Positive (dự đoán sai thành lớp này).
 - Ý nghĩa: trong số các mẫu được dự đoán là lớp X, bao nhiêu phần trăm là đúng.
- Recall (độ hồi gọi / sensitivity): tỷ lệ phát hiện đúng trên tất cả mẫu thực sự dương.
 - Công thức: $\text{recall} = TP / (TP + FN)$ (16)
 - Trong đó FN là số False Negative (bỏ sót mẫu thực sự thuộc lớp).
 - Ý nghĩa: trong số tất cả mẫu thực sự thuộc lớp X, mô hình bắt đúng bao nhiêu.
- F1-score: trung bình điều hòa giữa precision và recall.
 - Công thức: $F1 = 2 * (\text{precision} * \text{recall}) / (\text{precision} + \text{recall})$ (17)
 - Ý nghĩa: cân bằng giữa precision và recall; hữu ích khi cần tradeoff.
- Support: số lượng mẫu thực tế thuộc mỗi lớp trong tập kiểm thử.
 - Ý nghĩa: cho biết trọng số thực tế của mỗi lớp.

- Accuracy: tỷ lệ dự đoán đúng trên toàn bộ mẫu.
 - Công thức: $\text{accuracy} = (\text{tổng TP cho mọi lớp}) / \text{tổng mẫu}$ (18)
 - Ý nghĩa: thước đo tổng thể, nhưng nhạy với dữ liệu lệch lớp.
- Macro avg (trung bình macro):
 - Tính trung bình kiểu unweighted của metric (precision/recall/f1) qua tất cả lớp.
 - Ý nghĩa: cho mức hiệu năng trung bình mỗi lớp, coi mỗi lớp bằng nhau (phù hợp khi quan tâm đến lớp nhỏ).
- Weighted avg (trung bình có trọng số):
 - Trung bình của metric qua các lớp, trọng số là support (số mẫu mỗi lớp).
 - Ý nghĩa: phản ánh hiệu năng tổng thể mà tính đến phân bố lớp (lớp phổ biến ảnh hưởng nhiều hơn).

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ XUẤT

3.1. Tổng quan Mô hình Đề xuất và Định hướng Tiếp cận

Trong bối cảnh chất lượng không khí tại Thành phố Hồ Chí Minh có nhiều biến động theo thời gian và chịu ảnh hưởng bởi các yếu tố khí tượng, việc dự báo sớm các chỉ số ô nhiễm có ý nghĩa quan trọng đối với công tác giám sát môi trường và cảnh báo sức khỏe cộng đồng. Ở các chương trước, nghiên cứu đã tập trung phân tích bài toán dự đoán nồng độ bụi mịn $PM_{2.5}$. Tuy nhiên, để nâng cao giá trị ứng dụng thực tiễn của mô hình, nghiên cứu này đề xuất mở rộng sang bài toán dự báo Chỉ số Chất lượng Không khí (AQI) dưới hai dạng: AQI dạng số và AQI dạng phân loại.

Khác với $PM_{2.5}$ là đại lượng đo lường nồng độ bụi mịn trong không khí, AQI là chỉ số tổng hợp phản ánh mức độ ảnh hưởng của chất lượng không khí đến sức khỏe con người theo cách trực quan hơn. Do đó, việc dự báo AQI không chỉ mang ý nghĩa về mặt kỹ thuật mà còn có giá trị ứng dụng cao trong các hệ thống cảnh báo môi trường.

3.1.1. Mục tiêu của mô hình đề xuất

Dự báo AQI dạng số: Đây là bài toán hồi quy, trong đó mô hình học mối quan hệ giữa dữ liệu lịch sử và giá trị AQI ở thời điểm tiếp theo để đưa ra dự đoán dưới dạng số liên tục. Hướng tiếp cận này giúp duy trì tính chi tiết của dữ liệu và cho phép đánh giá trực tiếp mức chất lượng không khí theo thang điểm định lượng.

Dự báo AQI dạng phân loại: Đây là bài toán phân lớp đa lớp, trong đó mô hình dự đoán AQI theo các mức chất lượng không khí như *Good*, *Moderate*, *Unhealthy for Sensitive Groups*, *Unhealthy* và *Very Unhealthy*. Hướng tiếp cận này giúp chuyển các giá trị chỉ số thành các mức cảnh báo dễ hiểu, phù hợp hơn với mục tiêu hỗ trợ ra quyết định và truyền thông rủi ro môi trường.

3.1.2. Cấu trúc của mô hình đề xuất

Mô hình đề xuất không chỉ là một mô hình đơn lẻ, mà là một quy trình xử lý và huấn luyện hoàn chỉnh, gồm các bước chính sau:

- Thu thập và tổ chức dữ liệu: Dữ liệu được tổng hợp từ các biến thời gian, yếu tố thời tiết, $PM_{2.5}$, AQI và AQI Category.
- Làm sạch và tiền xử lý dữ liệu: Dữ liệu được kiểm tra để xử lý giá trị thiếu, giá trị bất thường, chuẩn hóa các biến số và mã hóa nhãn đối với bài toán phân loại.
- Xây dựng đặc trưng đầu vào: Dữ liệu chuỗi thời gian được chuyển sang dạng học có giám sát bằng cách sử dụng các giá trị trong quá khứ để dự đoán giá trị ở thời điểm tiếp theo. Nghiên cứu xem xét các khoảng thời gian trễ gồm 6 giờ, 12 giờ và 24 giờ để đánh giá ảnh hưởng của chiều dài chuỗi đầu vào đến hiệu quả dự báo.
- Thiết lập hai bài toán dự báo AQI: Từ cùng một bộ dữ liệu đầu vào, nghiên cứu xây dựng hai hướng dự báo:
 - Hồi quy cho AQI dạng số
 - Phân lớp cho AQI dạng chữ
- Huấn luyện và đánh giá mô hình: Mỗi bài toán được huấn luyện bằng các mô hình phù hợp và được đánh giá bằng các chỉ số tương ứng. Với AQI dạng số, các chỉ số RMSE, MAE và R^2 được sử dụng. Với AQI dạng phân loại, nghiên cứu sử dụng Accuracy, Precision, Recall, F1-score, Macro average và Weighted average.

3.1.3. Định hướng mô hình sử dụng trong nghiên cứu

Trong nghiên cứu này, việc lựa chọn mô hình được thực hiện dựa trên đặc điểm của từng bài toán dự báo AQI. Cụ thể, đối với AQI dạng số, mục tiêu đầu ra là một giá trị liên tục nên bài toán được tiếp cận theo hướng hồi quy. Trong khi đó, đối với AQI dạng phân loại, đầu ra là các mức chất lượng không khí rời rạc nên bài toán được xây dựng theo hướng phân lớp đa lớp. Từ đó, nghiên cứu triển khai các nhóm mô hình phù hợp để so sánh hiệu quả dự báo giữa các phương pháp truyền thống và các phương pháp học sâu hiện đại.

Đối với bài toán dự đoán AQI dạng số, nghiên cứu sử dụng các mô hình gồm SVR tuyến tính (SVR linear), SVR đa thức (SVR polynomial), Linear Regression, Random Forest, CNN và LSTM_CNN. Trong đó, Linear Regression được lựa chọn như một mô hình hồi quy cơ bản nhằm làm đường chuẩn ban đầu trong quá trình so sánh. Mô hình này có ưu điểm dễ triển khai, dễ diễn giải và cho phép đánh giá sơ bộ mối quan hệ tuyến tính giữa

các biến đầu vào với chỉ số AQI. SVR tuyến tính và SVR đa thức được đưa vào nghiên cứu nhằm kiểm tra khả năng mô hình hóa các quan hệ phi tuyến giữa dữ liệu môi trường và AQI, đặc biệt trong bối cảnh chất lượng không khí thường chịu tác động đồng thời của nhiều yếu tố khí tượng và yếu tố thời gian. Random Forest được sử dụng nhờ khả năng xử lý tốt dữ liệu phi tuyến, giảm hiện tượng quá khớp và đánh giá được hiệu quả của nhóm mô hình học máy dựa trên cây quyết định.

Bên cạnh các mô hình học máy truyền thống, nghiên cứu còn sử dụng các mô hình học sâu như CNN và LSTM_CNN cho bài toán AQI dạng số. CNN được lựa chọn với mục tiêu khai thác các mẫu cục bộ trong chuỗi dữ liệu đầu vào, đặc biệt là các xu hướng biến động ngắn hạn của các yếu tố môi trường trong các khoảng thời gian liên tiếp. Trong khi đó, LSTM_CNN là mô hình kết hợp giữa khả năng trích xuất đặc trưng của CNN và khả năng ghi nhớ phụ thuộc theo thời gian của LSTM. Việc sử dụng mô hình lai này nhằm kiểm tra xem việc kết hợp giữa học đặc trưng cục bộ và học quan hệ thời gian dài hạn có giúp nâng cao chất lượng dự báo AQI hay không.

Đối với bài toán dự đoán AQI dạng phân loại, nghiên cứu tập trung vào các mô hình học sâu gồm CNN_LSTM, Transformer và CNN_Transformer. Sở dĩ không sử dụng lại toàn bộ các mô hình hồi quy truyền thống như ở bài toán AQI dạng số là vì bài toán phân loại mức chất lượng không khí đòi hỏi mô hình phải học được ranh giới giữa các lớp, đồng thời nắm bắt được các đặc trưng động theo chuỗi thời gian. CNN_LSTM được sử dụng nhằm kết hợp khả năng trích xuất đặc trưng cục bộ từ chuỗi dữ liệu với khả năng mô hình hóa phụ thuộc theo thời gian của LSTM. Đây là hướng tiếp cận phù hợp đối với dữ liệu môi trường vốn có sự biến đổi liên tục theo giờ và có tính chu kỳ nhất định.

Ngoài ra, nghiên cứu còn triển khai mô hình Transformer, vốn là kiến trúc hiện đại dựa trên cơ chế attention. Điểm mạnh của Transformer là khả năng học được mối quan hệ giữa các thời điểm trong chuỗi mà không phụ thuộc hoàn toàn vào cấu trúc tuần tự như RNN hay LSTM. Điều này giúp mô hình có thể nắm bắt tốt hơn những ảnh hưởng xa trong chuỗi thời gian, đặc biệt khi AQI tại một thời điểm có thể chịu tác động từ trạng thái môi trường trước đó trong nhiều giờ. Trên cơ sở đó, nghiên cứu tiếp tục sử dụng mô hình CNN_Transformer nhằm kết hợp ưu điểm của CNN trong việc trích xuất đặc trưng cục bộ với ưu điểm của Transformer trong việc học các quan hệ xa hơn trong chuỗi. Mô

hình kết hợp này được kỳ vọng sẽ tăng khả năng nhận diện các mẫu biến động phức tạp của AQI và cải thiện hiệu suất phân loại.

Việc triển khai nhiều mô hình khác nhau trên cùng một bộ dữ liệu và cùng các mốc thời gian trễ 6 giờ, 12 giờ và 24 giờ có ý nghĩa quan trọng trong nghiên cứu. Thứ nhất, nó cho phép đánh giá khách quan khả năng dự báo của từng nhóm mô hình trong cùng điều kiện thực nghiệm. Thứ hai, nó giúp xác định xem loại mô hình nào phù hợp hơn với từng dạng bài toán, cụ thể là bài toán hồi quy cho AQI dạng số và bài toán phân lớp cho AQI dạng chữ. Thứ ba, việc thay đổi độ dài chuỗi đầu vào còn cho phép phân tích ảnh hưởng của thông tin lịch sử đến chất lượng dự báo, từ đó làm rõ liệu mô hình hoạt động hiệu quả hơn với chuỗi ngắn hạn hay chuỗi dài hơn. Đây là cơ sở quan trọng để lựa chọn mô hình tối ưu cho từng mục tiêu dự báo trong nghiên cứu.

3.1.4. Ý nghĩa của hướng tiếp cận đề xuất

Hướng tiếp cận được đề xuất trong nghiên cứu này có ý nghĩa cả về mặt học thuật lẫn thực tiễn ứng dụng. Nếu như các nghiên cứu trước chủ yếu tập trung vào dự báo nồng độ PM_{2.5} như một đại lượng kỹ thuật, thì nghiên cứu này mở rộng sang dự báo AQI dạng số và AQI dạng phân loại, từ đó đưa mô hình tiến gần hơn đến nhu cầu khai thác thực tế trong giám sát môi trường. Việc chuyển trọng tâm từ PM_{2.5} sang AQI không phải là sự thay thế hoàn toàn, mà là một bước phát triển tiếp theo nhằm biến dữ liệu kỹ thuật thành thông tin có khả năng hỗ trợ ra quyết định.

Đối với AQI dạng số, ý nghĩa lớn nhất của hướng tiếp cận này là cho phép mô hình đưa ra trực tiếp một chỉ số định lượng về chất lượng không khí. Khác với PM_{2.5} chỉ phản ánh riêng nồng độ bụi mịn, AQI dạng số mang tính trực quan hơn trong việc đánh giá mức độ ô nhiễm theo thang điểm. Điều này đặc biệt hữu ích trong các hệ thống giám sát tự động, nơi kết quả dự báo cần được thể hiện dưới dạng chỉ số rõ ràng để thuận tiện cho theo dõi, so sánh theo thời gian và hỗ trợ phân tích xu hướng biến động chất lượng không khí.

Đối với AQI dạng phân loại, hướng tiếp cận này có giá trị ứng dụng trực tiếp trong cảnh báo cộng đồng. Khi mô hình dự đoán được các mức như *Good*, *Moderate*, *Unhealthy for Sensitive Groups*, *Unhealthy* hay *Very Unhealthy*, kết quả đầu ra trở nên dễ hiểu hơn đối với người dân, nhà quản lý và các hệ thống cảnh báo tự động. Thay vì phải diễn giải từ

các giá trị số kỹ thuật, người sử dụng có thể nhanh chóng nhận biết mức độ rủi ro và đưa ra các phản ứng phù hợp như giảm thời gian hoạt động ngoài trời, cảnh báo cho nhóm nhạy cảm, hoặc tăng cường các biện pháp quản lý môi trường.

Ngoài ra, việc triển khai song song hai bài toán AQI dạng số và AQI dạng chữ còn giúp mở rộng phạm vi đánh giá mô hình. Ở bài toán AQI dạng số, mô hình được đánh giá ở góc độ độ chính xác định lượng, tức là mức độ gần giữa giá trị dự đoán và giá trị thực tế. Trong khi đó, ở bài toán AQI dạng chữ, mô hình được đánh giá ở góc độ khả năng nhận diện đúng mức cảnh báo chất lượng không khí. Sự kết hợp này cho phép nghiên cứu tiếp cận bài toán dự báo chất lượng không khí một cách toàn diện hơn, không chỉ dừng ở độ chính xác toán học mà còn xét đến khả năng hỗ trợ ứng dụng thực tế.

Về mặt học thuật, hướng tiếp cận đề xuất còn có giá trị ở chỗ tạo ra một khung so sánh giữa nhiều mô hình khác nhau trên cùng dữ liệu và cùng các mốc thời gian trễ. Qua đó, nghiên cứu không chỉ xác định mô hình nào đạt kết quả tốt hơn, mà còn góp phần làm rõ dạng mô hình nào phù hợp hơn với từng bài toán cụ thể. Chẳng hạn, một mô hình có thể hoạt động tốt trong dự báo AQI dạng số nhưng chưa chắc đã cho kết quả tốt nhất ở bài toán phân loại AQI. Việc phân tích song song như vậy giúp kết quả nghiên cứu có chiều sâu hơn và tạo cơ sở cho các nghiên cứu tiếp theo.

Từ góc độ thực tiễn, hướng tiếp cận này đặc biệt phù hợp với bối cảnh đô thị như Thành phố Hồ Chí Minh, nơi chất lượng không khí biến động theo thời gian và có ảnh hưởng trực tiếp đến sức khỏe cộng đồng. Một hệ thống dự báo không chỉ đưa ra nồng độ $PM_{2.5}$ mà còn có thể dự báo AQI số và phân loại AQI sẽ có khả năng phục vụ tốt hơn cho công tác quan trắc, cảnh báo sớm và hỗ trợ quản lý môi trường đô thị. Vì vậy, nghiên cứu này không chỉ mở rộng về mặt kỹ thuật mà còn tăng đáng kể tính ứng dụng của mô hình trong thực tế.

Quy trình nghiên cứu: Tiến trình nghiên cứu được chuẩn hóa qua 6 bước chiến lược: (1) Thu thập dữ liệu; (2) Làm sạch và tiền xử lý; (3) Xây dựng đặc trưng đầu vào; (4) Thiết lập hai bài toán dự báo AQI; (5) Huấn luyện mô hình học sâu; (6) Đánh giá kết quả thực nghiệm.

3.2. Mô tả và Tiền xử lý Dữ liệu Khí tượng

Quy trình tiền xử lý dữ liệu đóng vai trò quyết định đến hiệu suất của các mô hình học máy, đặc biệt là trong bài toán dự báo chuỗi thời gian khí tượng có độ nhiễu cao. Giai đoạn này tập trung vào việc chuyển đổi tập dữ liệu thô từ các trạm quan trắc thành một định dạng cấu trúc mà các thuật toán mạng nơ-ron tích chập (CNN) và mạng bộ nhớ ngắn hạn dài (LSTM) có thể khai thác tối đa các đặc trưng tiềm ẩn. Dữ liệu thô ban đầu được trích xuất từ tập tin Merged_PM2.5_AQI_18_23.csv, bao phủ giai đoạn từ năm 2018 đến năm 2023 với tần suất ghi nhận theo giờ.

3.2.1 Mô tả dữ liệu đầu vào

Tập dữ liệu nghiên cứu là một tập hợp các biến số đa chiều phản ánh trạng thái vật lý của khí quyển và mức độ ô nhiễm tại khu vực quan trắc. Cấu trúc của bộ dữ liệu bao gồm 16 cột thông tin chính, có thể chia thành bốn nhóm đặc trưng cơ bản :

- Nhóm định danh thời gian: Bao gồm các cột Date, Year, Month, Day, Hour, và YearMonth. Các thông số này cho phép mô hình học được tính chu kỳ theo ngày (diurnal cycles) và tính mùa vụ (seasonal trends) của nồng độ bụi mịn.
- Nhóm khí tượng động lực: Gồm hướng gió (wd) và tốc độ gió (ws). Đây là các yếu tố then chốt quyết định sự phát tán hoặc tích tụ của các hạt lơ lửng trong không gian đô thị.
- Nhóm nhiệt - ẩm và bức xạ: Bao gồm nhiệt độ (temp), lượng mưa (Rainfall), chỉ số lá thấp (low_leaf), và bức xạ tia cực tím B (uvb). Các biến này ảnh hưởng trực tiếp đến các phản ứng hóa học tạo thành bụi mịn thứ cấp trong khí quyển.
- Nhóm chỉ số mục tiêu: Gồm nồng độ $PM_{2.5}$, chỉ số chất lượng không khí AQI và phân loại chất lượng AQI Category. Các giá trị này phục vụ cho cả bài toán hồi quy (dự đoán nồng độ số lượng) và bài toán phân loại (dự đoán mức độ cảnh báo sức khỏe).

Qua phân tích định lượng trên 38 bản ghi đầu tiên, nghiên cứu xác định được các đặc tính thống kê quan trọng:

- Nhiệt độ (temp): Được ghi nhận trong đơn vị Kelvin, dao động từ mức cực tiểu 295.66K (tương đương 22.5°C) đến cực đại 304.05K (tương đương 30.9°C). Sự biến thiên này cho thấy biên độ nhiệt trong ngày có ảnh hưởng nhất định đến sự ổn định của lớp biên khí quyển.
- Tốc độ gió (ws): Duy trì ở mức thấp, từ 0.1 m/s đến 2.4 m/s. Tốc độ gió thấp là điều kiện lý tưởng cho sự hình thành các đợt ô nhiễm cục bộ do khả năng khuếch tán kém.
- Bức xạ UVB (uvb): Thể hiện tính chu kỳ mặt trời rõ rệt, đạt đỉnh cao nhất là 348,480.62 đơn vị tại các giờ trưa và giảm hoàn toàn về 0 trong các khung giờ tối.
- Nồng độ PM_{2.5}: Ghi nhận các giá trị từ 12 $\mu\text{g}/\text{m}^3$ đến 79 $\mu\text{g}/\text{m}^3$

Các giá trị này tương ứng với các danh mục AQI từ "Good" đến "Unhealthy".

3.2.2. Xử lý giá trị khuyết và chuẩn hoá dữ liệu

Dữ liệu thực tế từ các cảm biến IoT thường không tránh khỏi tình trạng mất mát tín hiệu do lỗi phần cứng hoặc gián đoạn mạng truyền dẫn. Trong tập dữ liệu thực nghiệm, biến tốc độ gió (ws) được phát hiện có giá trị khuyết (null) tại bản ghi lúc 08:00 ngày 2018-01-01. Để giải quyết vấn đề này, nghiên cứu áp dụng quy trình làm sạch theo các bước sau:

- Phát hiện và Xử lý giá trị khuyết: Đối với các biến khí tượng có tính tự tương quan cao theo thời gian như tốc độ gió và nhiệt độ, phương pháp nội suy tuyến tính (linear interpolation) được ưu tiên sử dụng để lấp đầy các khoảng trống dữ liệu ngắn. Đối với các cột có tỷ lệ mất mát dưới 5%, việc loại bỏ bản ghi có thể được thực hiện nếu không làm đứt quãng chuỗi thời gian quá dài.
- Chuẩn hóa thang đo (Feature Scaling): Do các biến có đơn vị và biên độ khác nhau rất lớn (ví dụ: uvb lên tới hàng trăm nghìn đơn vị trong khi Rainfall thường rất nhỏ), việc đưa tất cả về cùng một không gian số là bắt buộc để đảm bảo sự hội tụ của thuật toán Gradient Descent. Phương pháp Min-Max Scaling được áp dụng để chuyển đổi dữ liệu về khoảng :

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (19)$$

- Kỹ thuật hóa đặc trưng (Feature Engineering): Các cột Date được chuyển đổi thành các thành phần số học. Đặc biệt, biến Hour (giờ) và Month (tháng) được mã hóa bằng hàm lượng giác (Sine/Cosine encoding) để bảo toàn tính chất vòng lặp (ví dụ: giờ 23 và giờ 0 được xem là gần nhau về mặt toán học).
- Tạo cấu trúc cửa sổ trượt (Sliding Window Construction): Để huấn luyện các mô hình dự báo chuỗi thời gian, dữ liệu được tổ chức lại dưới dạng các cặp (Input, Output). Ví dụ, để dự báo PM_{2.5} cho 6 giờ tiếp theo, mô hình sẽ nhận đầu vào là chuỗi các đặc trưng của n giờ quá khứ.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1. Mô tả tập dữ liệu thực nghiệm

Thực nghiệm trong nghiên cứu được tiến hành trên tập dữ liệu khí tượng và chất lượng không khí tại khu vực Thành phố Hồ Chí Minh. Dữ liệu được thu thập với tần suất hàng giờ trong giai đoạn từ năm 2018 đến hết năm 2023, đảm bảo tính liên tục và cung cấp đủ khối lượng mẫu cho các mô hình học sâu trích xuất đặc trưng.

Sau quá trình tiền xử lý được trình bày trong Chương 3, dữ liệu được chuyển đổi về dạng phù hợp cho bài toán dự báo chuỗi thời gian (supervised learning), trong đó các quan sát trước đó được sử dụng làm đầu vào để dự đoán giá trị $PM_{2.5}$ trong tương lai.

4.1.1. Phân chia tập dữ liệu (Data Splitting)

Để đảm bảo tính thực tiễn và khả năng tổng quát hóa của mô hình, nghiên cứu áp dụng phương pháp phân chia dữ liệu theo trình tự thời gian (time-series split) thay vì chia ngẫu nhiên.

Cụ thể, toàn bộ dữ liệu được chia thành hai tập chính:

- Tập huấn luyện (Training Set): Bao gồm dữ liệu từ 01/01/2018 đến hết 31/12/2021, chiếm khoảng 80% tổng số mẫu sau khi tiền xử lý và xây dựng dữ liệu đầu vào. Giai đoạn này cung cấp các đặc trưng quan trọng như chu kỳ ngày và đêm, biến đổi theo mùa và các xu hướng khí tượng để mô hình học tập.
- Tập kiểm tra (Testing Set): Bao gồm dữ liệu từ 01/01/2022 đến hết 31/12/2023, chiếm khoảng 20% còn lại. Đây là tập dữ liệu hoàn toàn độc lập, chưa từng được sử dụng trong quá trình huấn luyện, nhằm đánh giá khách quan khả năng dự báo của mô hình trên dữ liệu tương lai.


Việc phân chia theo thời gian giúp tránh hiện tượng rò rỉ dữ liệu (data leakage), đảm bảo mô hình chỉ học từ dữ liệu quá khứ và dự đoán cho tương lai, phù hợp với bản chất của bài toán dự báo chuỗi thời gian.

4.1.2. Đặc trưng dữ liệu và phân tích tương quan

Tập dữ liệu bao gồm các nhóm đặc trưng đầu vào có ảnh hưởng trực tiếp đến sự hình thành và phát tán bụi mịn:

- Nhóm biến khí tượng: Nhiệt độ, tốc độ gió, lượng mưa, độ ẩm, bức xạ UVB.
- Nhóm biến thời gian: Các chỉ số về giờ, ngày và tháng đã được mã hóa để mô hình nhận diện tính chu kỳ.
- Biến mục tiêu: Nồng độ $PM_{2.5}$ ($\mu g/m^3$).

Thông qua việc phân tích ma trận tương quan (Heatmap), nghiên cứu nhận thấy nồng độ $PM_{2.5}$ có tương quan nghịch rõ rệt với tốc độ gió và lượng mưa (gió mạnh và mưa giúp phát tán bụi). Ngược lại, nồng độ bụi thường có xu hướng tăng cao vào các khung giờ cao điểm giao thông, cho thấy sự ảnh hưởng mạnh mẽ từ hoạt động của con người.



Hình 8: Ma trận tương quan giữa các biến (Heatmap)

4.1.3. Phân tích xu hướng và tính chu kỳ

Dữ liệu thực nghiệm cho thấy nồng độ PM_{2.5} tại TP.HCM không biến thiên ngẫu nhiên mà tuân theo các quy luật cụ thể:

- Tính chu kỳ ngày (Diurnal Cycle): Nồng độ thường đạt đỉnh vào buổi sáng (khoảng 7h-9h) và chiều tối (17h-19h). Đây là hệ quả của sự kết hợp giữa phát thải giao thông và hiện tượng nghịch nhiệt tầng thấp vào ban đêm.
- Tính chu kỳ mùa (Seasonality): Có sự phân hóa rõ rệt giữa mùa khô và mùa mưa. Trong mùa khô, do điều kiện khí quyển ổn định và ít mưa, nồng độ PM_{2.5} trung bình thường cao hơn đáng kể so với mùa mưa.
- Xu hướng theo năm (Yearly Trend): Bên cạnh các chu kỳ ngắn hạn, dữ liệu cũng cho thấy sự biến động của nồng độ PM_{2.5} trong giai đoạn 2018–2023. Xu hướng này phản ánh tác động tổng hợp của các yếu tố như điều kiện khí hậu, mức độ đô thị hóa và các chính sách kiểm soát ô nhiễm không khí theo thời gian.

Việc phân tích kỹ lưỡng các đặc trưng này đóng vai trò quan trọng, giúp giải thích lý do tại sao các kiến trúc như CNN (mạnh về trích xuất đặc trưng cục bộ) và LSTM (mạnh về ghi nhớ chuỗi thời gian) lại đạt hiệu suất cao trong các thí nghiệm tiếp theo.

4.2. Thiết lập Thực nghiệm và Chỉ số Đánh giá

4.2.1. Cấu hình thực nghiệm và Siêu tham số (Hyperparameters)

Quá trình huấn luyện các mô hình được thực hiện trên môi trường Python với các thư viện hỗ trợ mạnh mẽ như TensorFlow/Keras và Scikit-learn. Để đảm bảo tính công bằng và tìm ra hiệu suất tối ưu, các siêu tham số được thiết lập dựa trên quá trình thử nghiệm và tinh chỉnh (fine-tuning):

- Bộ tối ưu hóa (Optimizer): Sử dụng Adam (Adaptive Moment Estimation). Đây là lựa chọn phổ biến nhờ khả năng tự điều chỉnh tốc độ học, giúp mô hình hội tụ nhanh và ổn định hơn so với SGD truyền thống.
- Tốc độ học (Learning Rate): Được thiết lập ở mức 0.001. Mức này đủ nhỏ để tránh hiện tượng vượt quá điểm hội tụ nhưng đủ lớn để đảm bảo tốc độ huấn luyện.

- Số lượng chu kỳ huấn luyện (Epochs): Thiết lập tối đa 100 epochs. Tuy nhiên, để tránh hiện tượng quá khớp, nghiên cứu sử dụng cơ chế Early Stopping (dừng sớm nếu hàm mất mát trên tập kiểm định không cải thiện sau một số chu kỳ nhất định).
- Kích thước lô (Batch Size): Sử dụng kích thước 32, 64 hoặc 128 tùy theo độ phức tạp của kiến trúc, giúp cân bằng giữa tốc độ tính toán và độ chính xác của gradient.
- Hàm mất mát (Loss Function): Sử dụng Mean Squared Error (MSE) cho các bài toán hồi quy nồng độ PM_{2.5}, vì nó tập trung tối ưu hóa và giảm thiểu các sai số lớn.

4.2.2. Chỉ số đánh giá mô hình Hồi quy

Để đo lường sai số định lượng giữa giá trị dự báo và giá trị thực tế của nồng độ PM_{2.5}, nghiên cứu sử dụng các thước đo chuẩn sau:

- RMSE (Root Mean Squared Error): Sai số bình phương trung bình căn. RMSE đặc biệt nhạy cảm với các sai số lớn, giúp đánh giá khả năng của mô hình trong việc bắt kịp các thời điểm ô nhiễm cực đại.
- MAE (Mean Absolute Error): Sai số tuyệt đối trung bình, cung cấp cái nhìn thực tế về độ lệch trung bình giữa giá trị dự báo và thực tế theo đơn vị $\mu\text{g}/\text{m}^3$.
- R^2 (Coefficient of Determination): Hệ số xác định, cho biết tỷ lệ phần trăm sự biến động của dữ liệu mà mô hình có thể giải thích được. Giá trị R^2 càng gần 1, mô hình càng có độ khớp tốt.

4.2.3. Chỉ số đánh giá bài toán Phân loại (AQI)

Bên cạnh dự báo nồng độ, nghiên cứu còn đánh giá khả năng phân loại mức độ ô nhiễm theo chỉ số AQI thông qua các chỉ số:

- Precision (Độ chính xác): Tỷ lệ các mẫu được dự báo là "Ô nhiễm" thực sự nằm trong ngưỡng ô nhiễm.
- Recall (Độ hồi gọi): Tỷ lệ các đợt ô nhiễm thực tế ngoài môi trường được mô hình nhận diện thành công.
- F1-score: Trung bình điều hòa giữa Precision và Recall, giúp đánh giá hiệu suất tổng thể ngay cả khi tập dữ liệu giữa các mức AQI bị mất cân bằng (ví dụ: số ngày không khí sạch nhiều hơn số ngày ô nhiễm nặng).

4.3. Phân tích Kết quả Dự báo hồi quy PM_{2.5}

Hiệu suất của các mô hình thay đổi rõ rệt theo từng mốc thời gian dự báo (6 giờ, 12 giờ và 24 giờ), phản ánh sự khác biệt trong khả năng học và trích xuất đặc trưng của từng kiến trúc. Đặc biệt, sự biến thiên này cho thấy mức độ phù hợp của từng mô hình đối với dữ liệu chuỗi thời gian có tính động cao như PM_{2.5}.

Bảng 1: Kết quả dự báo tại mốc 6 giờ

Mô hình	Test RMSE	Test MAE	Test R ²
CNN	8.5972	5.9878	0.8959
Linear Regression	8.6574	5.9508	0.8944
Random Forest	8.7958	6.1041	0.8910
LSTM_CNN	9.2973	6.6377	0.8782
SVR (linear)	11.5907	9.2792	0.8107
SVR (poly)	14.4536	11.3136	0.7057

Tại mốc 6 giờ, kết quả cho thấy một sự cạnh tranh sát sao giữa các mô hình truyền thống và học sâu.

- Trước hết, mô hình CNN đạt hiệu suất tốt nhất với RMSE thấp nhất (8.5972) và R² cao nhất (0.8959). Điều này cho thấy khả năng của CNN trong việc khai thác các đặc trưng cục bộ thông qua cơ chế tích chập (convolution), giúp phát hiện các biến động ngắn hạn trong dữ liệu PM_{2.5} một cách hiệu quả.
- Đáng chú ý, Linear Regression cho kết quả gần tương đương (R² = 0.8944), cho thấy trong khoảng thời gian ngắn, nồng độ PM_{2.5} có tính tự tương quan cao và chịu ảnh hưởng mạnh từ các yếu tố khí tượng tức thời. Do đó, mối quan hệ giữa đầu vào và đầu ra mang tính tuyến tính rõ rệt, giúp các mô hình đơn giản vẫn đạt hiệu suất cao.
- Ngược lại, các mô hình phức tạp hơn như LSTM_CNN chưa thể hiện được lợi thế do chưa cần đến khả năng ghi nhớ dài hạn trong bối cảnh dự báo ngắn hạn. Đặc biệt, SVR với kernel đa thức cho kết quả thấp nhất (R² = 0.7057), cho thấy hiện tượng khớp quá (overfitting) khi mô hình cố gắng biểu diễn dữ liệu trong không gian đặc trưng phi tuyến phức tạp không cần thiết.

Bảng 2: Kết quả dự báo tại mốc 12 giờ

Mô hình	Test RMSE	Test MAE	Test R ²
CNN	8.5585	5.9049	0.8968
Linear Regression	8.5998	5.8692	0.8958
Random Forest	8.6787	6.0024	0.8939
LSTM_CNN	9.1333	6.5614	0.8825
SVR (linear)	11.5157	9.1865	0.8132
SVR (poly)	14.9520	11.8070	0.6851

Khi tầm nhìn dự báo mở rộng lên 12 giờ, xu hướng thay đổi bắt đầu xuất hiện rõ rệt hơn ở các mô hình học máy.

- CNN tiếp tục duy trì vị trí dẫn đầu với hiệu suất cải thiện nhẹ (RMSE giảm xuống 8.5585), cho thấy khả năng ổn định trong việc trích xuất đặc trưng ngay cả khi độ trễ thời gian tăng lên.
- Điểm đáng chú ý tại mốc này là sự cải thiện của mô hình LSTM_CNN (R² tăng từ 0.8782 lên 0.8825). Khi khoảng thời gian dự báo dài hơn, dữ liệu bắt đầu chịu ảnh hưởng của các yếu tố mang tính chu kỳ, chẳng hạn như sự thay đổi giữa ngày và đêm. Thành phần LSTM trong mô hình đã phát huy vai trò trong việc ghi nhớ các phụ thuộc theo thời gian (temporal dependencies), từ đó cải thiện khả năng dự báo.
- Trong khi đó, Linear Regression và Random Forest vẫn duy trì hiệu suất ổn định, cho thấy dữ liệu vẫn còn mang tính cấu trúc rõ ràng. Ngược lại, SVR (poly) tiếp tục suy giảm hiệu suất, phản ánh việc mô hình không thích ứng tốt với sự gia tăng độ phức tạp của dữ liệu theo thời gian.

Bảng 3 Kết quả dự báo tại mốc 24 giờ

Mô hình	Test RMSE	Test MAE	Test R ²
CNN	8.4062	5.7167	0.9005
Linear Regression	8.5297	5.7691	0.8975
Random Forest	8.6397	5.9203	0.8948
LSTM_CNN	9.2366	6.6492	0.8798
SVR (linear)	11.2193	8.8267	0.8227
SVR (poly)	15.3908	12.0445	0.6663

Mốc 24 giờ là mốc quan trọng nhất vì nó bao hàm trọn vẹn một chu kỳ sinh hoạt của con người và biến động của lớp biên khí quyển.

- Tại đây, CNN đạt hiệu suất cao nhất trong toàn bộ thí nghiệm với $R^2 = 0.9005$ và RMSE thấp nhất (8.4062). Kết quả này cho thấy mô hình đã học được các đặc trưng mang tính chu kỳ 24 giờ (diurnal cycle), bao gồm sự thay đổi của hoạt động giao thông, công nghiệp và điều kiện khí quyển. Nhờ cơ chế tích chập, CNN có khả năng nhận diện các mẫu lặp theo thời gian và giảm ảnh hưởng của nhiễu, từ đó nâng cao độ chính xác dự báo.
- Linear Regression và Random Forest vẫn giữ được hiệu suất ổn định (R^2 xấp xỉ 0.89), cho thấy dữ liệu $PM_{2.5}$ có cấu trúc rõ ràng ngay cả trong dự báo dài hạn. Tuy nhiên, các mô hình này không thể khai thác được các mối quan hệ phi tuyến và chu kỳ phức tạp như CNN.
- Ngược lại, SVR (poly) cho thấy sự suy giảm nghiêm trọng (R^2 chỉ còn 0.6663), khẳng định rằng việc sử dụng không gian đặc trưng phi tuyến bậc cao không phù hợp với dữ liệu có nhiễu nhiều và biến động như $PM_{2.5}$. Khi thời gian dự báo tăng, mô hình này dễ bị “nhiều hóa” và mất khả năng tổng quát hóa.

Từ các kết quả thực nghiệm, có thể nhận thấy rằng CNN là mô hình phù hợp nhất cho bài toán dự báo nồng độ $PM_{2.5}$ trong nghiên cứu này. Không chỉ đạt độ chính xác cao, CNN còn thể hiện tính ổn định vượt trội khi tầm nhìn dự báo tăng dần.

Trong khi đó, Linear Regression đóng vai trò là một mô hình nền mạnh nhờ khả năng khai thác tốt các quan hệ tuyến tính trong dữ liệu. Tuy nhiên, hạn chế của nó dần bộc lộ khi cần mô hình hóa các đặc trưng phi tuyến và phụ thuộc dài hạn.

Các mô hình dựa trên hàm nhân như SVR cho thấy hiệu suất kém hơn đáng kể, đặc biệt trong dự báo dài hạn, do không thích ứng tốt với đặc tính nhiễu và biến động phức tạp của dữ liệu môi trường.

Nhìn chung, kết quả nghiên cứu khẳng định rằng đối với bài toán dự báo chất lượng không khí, các kiến trúc học sâu dựa trên tích chập có khả năng khai thác đặc trưng hiệu quả hơn và mang lại độ tin cậy cao hơn so với các phương pháp truyền thống.

4.4. Phân tích kết quả phân loại AQI và đánh giá sai số

4.4.1 Kết quả của từng mô hình

Kết quả của mô hình CNN_LSTM

Bảng 4: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 6 tiếng

6 tiếng	Precision	Recall	F1-score	support
Good	0.71	0.86	0.78	1153
Moderate	0.94	0.83	0.88	5146
Unhealthy	0.74	0.77	0.75	316
Unhealthy for Sensitive Groups	0.58	0.80	0.67	909
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.83	7525
Marco avg	0.59	0.65	0.62	7525
Weight avg	0.85	0.83	0.84	7525

Good (support = 1.153, chiếm ~15,3%): Precision = 0.71, Recall = 0.86, F1 = 0.78. Mô hình có khả năng nhận diện tốt các mẫu thực sự Good (recall cao), nhưng precision chỉ ở mức trung bình cho thấy có khá nhiều mẫu thuộc các lớp khác (chủ yếu Moderate) bị nhầm thành Good.

Moderate (support = 5.146, chiếm ~68,4% – lớp chiếm ưu thế tuyệt đối): Precision = 0.94, Recall = 0.83, F1 = 0.88. Đây là lớp có hiệu suất tốt nhất. Precision rất cao nghĩa là khi mô hình dự đoán Moderate thì độ tin cậy gần như chắc chắn (chỉ 6% sai). Recall hơi thấp hơn cho thấy vẫn còn một phần mẫu Moderate bị nhầm sang Good hoặc Unhealthy for Sensitive Groups. Vì support cực lớn, lớp này đóng góp mạnh nhất vào accuracy tổng thể.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.74, Recall = 0.77, F1 = 0.75. Hiệu suất khá cân bằng ở mức trung bình-cao. Mô hình nhận diện tương đối tốt lớp này, nhưng vẫn có nhầm lẫn với các lớp lân cận (Unhealthy ↔ Unhealthy for Sensitive Groups).

Unhealthy for Sensitive Groups (support = 909, chiếm ~12,1%): Precision = 0.58, Recall = 0.80, F1 = 0.67. Đây là lớp có precision thấp nhất (chỉ 58%). Mô hình thường “quá mức” dự đoán lớp này, dẫn đến F1-score giảm rõ rệt dù recall vẫn đạt 80%. Đây là điểm yếu rõ ràng của mô hình.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Với chỉ 1 mẫu, mô hình không dự đoán đúng bất kỳ trường hợp nào.

Accuracy = 0.83 (83%): Mức độ chính xác tổng thể khá tốt cho bài toán dự báo AQI đa lớp, đặc biệt khi dữ liệu thời gian (6 tiếng) có tính biến động cao.

Macro avg (0.59 | 0.65 | 0.62): Trung bình không trọng số, bị kéo xuống mạnh bởi lớp Very Unhealthy và Unhealthy for Sensitive Groups. Cho thấy mô hình chưa xử lý tốt các lớp thiểu số.

Weighted avg (0.85 | 0.83 | 0.84): Trung bình có trọng số theo support, cao hơn nhiều vì ưu tiên lớp Moderate chiếm đa số. Đây là chỉ số thực tế hơn để đánh giá mô hình trên tập dữ liệu hiện tại.

Mô hình CNN_LSTM đạt hiệu suất tốt trên lớp chiếm ưu thế (Moderate), nhưng gặp khó khăn rõ rệt với các lớp hiếm và lớp Unhealthy for Sensitive Groups. Độ lệch giữa macro avg và weighted avg cho thấy vấn đề class imbalance là nguyên nhân chính làm giảm chất lượng tổng thể. Trong thực tế ứng dụng tại khu vực có nồng độ bụi PM2.5 biến động mạnh như TP.HCM, việc precision của lớp “Unhealthy for Sensitive Groups” thấp có thể dẫn đến cảnh báo sai nhiều, gây mất lòng tin người dùng. Cần các kỹ thuật cân bằng dữ liệu (class weights, oversampling, hoặc merge lớp Very Unhealthy vào Unhealthy) để cải thiện macro F1-score.



Hình 9: Kết quả dự đoán mô hình CNN_LSTM 6 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 989 (85,8%). Sai: 161 → Moderate, 3 → Unhealthy for Sensitive Groups. → Mô hình khá tốt với Good, nhưng vẫn nhầm 14% sang Moderate (lớp liền kề).

Actual Moderate (5.146 mẫu): Dự đoán đúng: 4.282 (83,2%). Sai lớn: 406 → Good, 450 → Unhealthy for Sensitive Groups, 8 → Unhealthy. → Đây là nguồn sai lớn nhất của ma trận. Mô hình có xu hướng “bi quan” một chút: 450 mẫu Moderate bị đẩy lên Unhealthy for Sensitive Groups (tăng mức độ ô nhiễm) và 406 bị đẩy xuống Good (giảm mức độ).

Actual Unhealthy (316 mẫu): Dự đoán đúng: 243 (76,9%). Sai: 71 → Unhealthy for Sensitive Groups, 2 → Moderate. → 22,5% bị nhầm sang lớp liền kề cao hơn (Unhealthy for Sensitive Groups).

Actual Unhealthy for Sensitive Groups (909 mẫu): Dự đoán đúng: 729 (80,2%). Sai: 102 → Moderate, 78 → Unhealthy. → 19,8% bị nhầm xuống các lớp thấp hơn. Đây là nguyên nhân chính làm precision của lớp này thấp (nhiều mẫu khác cũng bị đẩy vào đây).

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy. → Mẫu hiếm hoàn toàn bị nhầm sang lớp liền kề.

Nhầm lẫn chủ yếu xảy ra giữa các lớp liền kề trên thang AQI (Good ↔ Moderate, Moderate ↔ Unhealthy for Sensitive Groups, Unhealthy ↔ Unhealthy for Sensitive Groups). Điều này hoàn toàn hợp lý vì ranh giới giữa các mức AQI không phải là cứng nhắc mà phụ thuộc vào biến động ngắn hạn của dữ liệu thời gian (6 tiếng).

Không có nhầm lẫn quá xa (ví dụ: Good → Unhealthy hoặc Very Unhealthy → Good) → mô hình nắm khá tốt thứ tự thứ bậc của AQI.

Bảng 5: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 12 tiếng

12 tiếng	Precision	Recall	F1-score	support
Good	0.68	0.87	0.76	1153
Moderate	0.94	0.81	0.87	5146
Unhealthy	0.72	0.76	0.74	316
Unhealthy for Sensitive Groups	0.56	0.78	0.65	908
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.82	7524
Marco avg	0.58	0.65	0.61	7524
Weight avg	0.85	0.82	0.82	7524

Good (support = 1.153, chiếm ~15,3%): Precision = 0.68, Recall = 0.87, F1 = 0.76. Recall vẫn rất cao (0.87), cho thấy mô hình vẫn nhận diện tốt các mẫu thực sự thuộc mức Good. Tuy nhiên, precision giảm so với mô hình 6 tiếng (từ 0.71 xuống 0.68). Điều này nghĩa là có nhiều mẫu thuộc lớp khác (chủ yếu Moderate) bị nhầm thành Good hơn so với dự báo 6 tiếng.

Moderate (support = 5.146, chiếm ~68,4% – vẫn là lớp chiếm ưu thế tuyệt đối): Precision = 0.94, Recall = 0.81, F1 = 0.87. Precision vẫn giữ ở mức rất cao (0.94), cho thấy khi mô hình dự đoán Moderate thì độ tin cậy vẫn rất tốt. Tuy nhiên, recall giảm nhẹ so với mô hình 6 tiếng (từ 0.83 xuống 0.81). Nhiều mẫu Moderate hơn bị nhầm sang các lớp khác, đặc biệt là Good và Unhealthy for Sensitive Groups. Lớp này vẫn đóng góp lớn nhất vào accuracy tổng thể.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.72, Recall = 0.76, F1 = 0.74. Hiệu suất giảm nhẹ so với mô hình 6 tiếng (F1 từ 0.75 xuống 0.74). Cả precision và recall đều giảm một chút, cho thấy khi dự báo xa hơn (12 tiếng), mô hình khó phân biệt lớp Unhealthy hơn, dễ nhầm lẫn với các lớp lân cận.

Unhealthy for Sensitive Groups (support = 908, chiếm ~12,1% – giảm 1 mẫu so với 6 tiếng): Precision = 0.56, Recall = 0.78, F1 = 0.65. Đây tiếp tục là điểm yếu rõ ràng nhất. Precision giảm thêm (từ 0.58 xuống 0.56), cho thấy mô hình càng dự đoán “quá mức” lớp này khi thời gian dự báo dài hơn. Recall cũng giảm nhẹ, dẫn đến F1-score thấp. Số false positive vào lớp này vẫn ở mức cao.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Vẫn hoàn toàn không dự đoán đúng mẫu hiếm này (giống hệt mô hình 6 tiếng). Với chỉ 1 mẫu, lớp này vẫn nằm ngoài khả năng học của mô hình.

Accuracy = 0.82 (82%): Giảm nhẹ so với mô hình 6 tiếng (từ 83% xuống 82%). Điều này cho thấy hiệu suất tổng thể giảm khi dự báo xa hơn, phù hợp với bản chất của bài toán dự báo thời gian (dự báo càng xa thì độ không chắc chắn càng tăng).

Macro avg (0.58 | 0.65 | 0.61): Thấp hơn so với mô hình 6 tiếng (F1 macro từ 0.62 xuống 0.61), cho thấy khả năng xử lý các lớp thiểu số kém hơn khi thời gian dự báo dài.

Weighted avg (0.85 | 0.82 | 0.82): Vẫn ở mức khá cao nhờ lớp Moderate chiếm đa số, nhưng cũng giảm nhẹ so với 6 tiếng.

So với mô hình 6 tiếng, hiệu suất của CNN_LSTM 12 tiếng giảm nhẹ ở hầu hết các chỉ số. Độ lệch giữa macro avg và weighted avg vẫn lớn, khẳng định class imbalance vẫn là vấn đề chính. Khi dự báo dài hạn hơn (12 tiếng), mô hình có xu hướng lạc quan hơn với lớp Good (recall cao nhưng precision thấp) và bi quan hơn với lớp Unhealthy for Sensitive Groups (precision thấp). Trong bối cảnh TP.HCM, việc precision của lớp “Unhealthy for Sensitive Groups” chỉ còn 0.56 có thể dẫn đến nhiều cảnh báo sai, đặc biệt ảnh hưởng đến nhóm nhạy cảm. Việc accuracy giảm khi tăng thời gian dự báo là điều dễ hiểu, nhưng khoảng cách không quá lớn cho thấy mô hình vẫn có khả năng duy trì ổn định ở mức chấp nhận được.



Hình 10: Kết quả dự đoán mô hình CNN_LSTM 12 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 1.005 (87,2%). Sai: 145 → Moderate, 3 → Unhealthy for Sensitive Groups. → Tỷ lệ đúng tăng nhẹ so với mô hình 6 tiếng (từ 85,8% lên 87,2%). Mô hình vẫn nhầm một phần sang Moderate, nhưng ít hơn.

Actual Moderate (5.146 mẫu): Dự đoán đúng: 4.184 (81,3%). Sai lớn: 472 → Good, 481 → Unhealthy for Sensitive Groups, 9 → Unhealthy. → Đây vẫn là nguồn sai lớn nhất. So với 6 tiếng, số lượng bị đẩy lên Unhealthy for Sensitive Groups tăng (từ 450 lên 481), trong khi số bị đẩy xuống Good cũng tăng (từ 406 lên 472). Mô hình cho thấy xu hướng bi quan mạnh hơn khi dự báo 12 tiếng.

Actual Unhealthy (316 mẫu): Dự đoán đúng: 241 (76,3%). Sai: 72 → Unhealthy for Sensitive Groups, 2 → Moderate, 1 → Very Unhealthy. → Tỷ lệ đúng giảm nhẹ. Có 1 mẫu hiếm bị đẩy lên Very Unhealthy (khác với 6 tiếng chỉ đẩy xuống Unhealthy).

Actual Unhealthy for Sensitive Groups (908 mẫu): Dự đoán đúng: 709 (78,1%). Sai: 115 → Moderate, 84 → Unhealthy. → Tỷ lệ đúng giảm so với 6 tiếng (từ 80,2% xuống 78,1%). Số bị nhầm xuống Moderate tăng đáng kể (từ 102 lên 115), cho thấy mô hình khó duy trì ranh giới khi dự báo xa hơn.

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy. → Vẫn bị nhầm hoàn toàn sang lớp liền kề.

Nhầm lẫn vẫn chủ yếu tập trung vào các lớp liền kề (Good ↔ Moderate, Moderate ↔ Unhealthy for Sensitive Groups, Unhealthy ↔ Unhealthy for Sensitive Groups). Điều này tiếp tục hợp lý vì ranh giới AQI không sắc nét và biến động theo thời gian.

So với mô hình 6 tiếng, số lượng nhầm lẫn Moderate → Unhealthy for Sensitive Groups tăng (450 → 481), cho thấy khi dự báo dài hơn, mô hình có xu hướng dự đoán mức ô nhiễm cao hơn một chút.

Vẫn không có nhầm lẫn quá xa, chứng tỏ mô hình vẫn nắm tốt thứ tự thứ bậc của các mức AQI.

Bảng 6: Báo cáo phân loại chỉ số AQI mô hình CNN_LSTM 24 tiếng

24 tiếng	Precision	Recall	F1-score	support
Good	0.81	0.83	0.82	1153
Moderate	0.93	0.92	0.92	5146
Unhealthy	0.76	0.76	0.76	316
Unhealthy for Sensitive Groups	0.72	0.73	0.73	907
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.88	7522
Marco avg	0.64	0.65	0.65	7522
Weight avg	0.88	0.88	0.88	7522

Good (support = 1.153, chiếm ~15,3%): Precision = 0.81, Recall = 0.83, F1 = 0.82. So với hai mô hình trước, lớp Good có sự cải thiện rõ rệt. Precision tăng mạnh (từ 0.68 ở 12 tiếng lên 0.81), recall duy trì ở mức cao và cân bằng hơn. F1-score đạt 0.82 – cao nhất trong ba khoảng thời gian. Mô hình ít “optimistic” hơn, giảm đáng kể số lượng false positive cho lớp Good.

Moderate (support = 5.146, chiếm ~68,4% – vẫn là lớp chiếm ưu thế tuyệt đối): Precision = 0.93, Recall = 0.92, F1 = 0.92. Đây là hiệu suất tốt nhất từ trước đến nay cho lớp Moderate. Cả precision và recall đều rất cao và cân bằng (0.93 và 0.92). Recall tăng mạnh so với 12 tiếng (từ 0.81 lên 0.92), cho thấy mô hình nhận diện lớp Moderate chính xác hơn khi dự báo xa 24 tiếng. Lớp này tiếp tục là trụ cột chính góp phần vào accuracy tổng thể.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.76, Recall = 0.76, F1 = 0.76. Hiệu suất cân bằng và cải thiện so với 12 tiếng (F1 từ 0.74 lên 0.76). Cả hai chỉ số precision và recall đều ở mức khá, cho thấy mô hình xử lý lớp này ổn định hơn khi dự báo dài hạn.

Unhealthy for Sensitive Groups (support = 907, chiếm ~12,1% – giảm nhẹ so với trước): Precision = 0.72, Recall = 0.73, F1 = 0.73. Đây là cải thiện đáng kể nhất so với hai mô hình trước. Precision tăng mạnh (từ 0.56 ở 12 tiếng lên 0.72), recall cũng ổn định ở mức 0.73. F1-score đạt 0.73 – cao hơn nhiều so với 0.65 (12 tiếng) và 0.67 (6 tiếng). Mô hình giảm rõ rệt tình trạng “quá mức” dự đoán lớp này, làm giảm false positive đáng kể.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Vẫn không dự đoán đúng mẫu hiếm này, giống hệt hai mô hình trước.

Accuracy = 0.88 (88%): Tăng đáng kể so với 82% (12 tiếng) và 83% (6 tiếng). Đây là accuracy cao nhất trong ba mô hình, cho thấy hiệu suất tổng thể tốt hơn khi dự báo 24 tiếng.

Macro avg (0.64 | 0.65 | 0.65): Cải thiện rõ rệt so với trước (F1 macro từ 0.61–0.62 lên 0.65). Macro avg cao hơn cho thấy mô hình xử lý các lớp thiểu số (đặc biệt Unhealthy for Sensitive Groups) tốt hơn.

Weighted avg (0.88 | 0.88 | 0.88): Rất cân bằng và cao, phản ánh hiệu suất đồng đều hơn trên toàn bộ tập dữ liệu.

Khác hẳn với xu hướng thường thấy (hiệu suất giảm khi dự báo xa hơn), mô hình CNN_LSTM 24 tiếng lại cho kết quả tốt nhất trong ba khoảng thời gian. Cả precision, recall và F1-score đều cải thiện ở hầu hết các lớp, đặc biệt là Good và Unhealthy for Sensitive Groups. Độ lệch giữa macro avg và weighted avg thu hẹp đáng kể, chứng tỏ mô hình đã xử lý tốt hơn vấn đề class imbalance. Trong bối cảnh thực tế tại TP.HCM, kết quả này rất có ý nghĩa vì precision của lớp “Unhealthy for Sensitive Groups” tăng lên 0.72 giúp giảm cảnh báo sai, tăng độ tin cậy cho nhóm nhạy cảm. Tuy nhiên, lớp Very Unhealthy vẫn là điểm yếu cần khắc phục. Sự cải thiện này có thể xuất phát từ việc mô hình học được các xu hướng dài hạn ổn định hơn của dữ liệu AQI.



Hình 11: Kết quả dự đoán mô hình CNN_LSTM 24 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 952 (82,6%). Sai: 201 → Moderate. → Tỷ lệ đúng giảm nhẹ so với 12 tiếng nhưng precision cao hơn nhờ giảm nhầm lẫn từ các lớp khác vào Good. Chỉ nhầm sang Moderate (lớp liền kề), không có nhầm lẫn xa.

Actual Moderate (5.146 mẫu): Dự đoán đúng: 4.733 (92,0%). Sai: 223 → Good, 188 → Unhealthy for Sensitive Groups, 1 → Unhealthy. → Tỷ lệ đúng tăng mạnh so với hai mô hình trước (từ 81,3% ở 12 tiếng lên 92%). Số lượng bị đẩy lên Unhealthy for Sensitive Groups giảm đáng kể (từ 481 xuống 188), cho thấy mô hình ít “bi quan” hơn khi dự báo 24 tiếng. Đây là nguồn góp phần lớn vào accuracy cao.

Actual Unhealthy (316 mẫu): Dự đoán đúng: 241 (76,3%). Sai: 68 → Unhealthy for Sensitive Groups, 6 → Moderate, 1 → Very Unhealthy. → Tỷ lệ đúng giữ ổn định, nhằm lẫn chủ yếu với lớp liền kề cao hơn.

Actual Unhealthy for Sensitive Groups (907 mẫu): Dự đoán đúng: 662 (73,0%). Sai: 167 → Moderate, 77 → Unhealthy, 1 → Very Unhealthy. → Tỷ lệ đúng giảm nhẹ so với 12 tiếng, nhưng precision tăng mạnh nhờ giảm số lượng mẫu từ lớp khác bị đẩy vào lớp này (đặc biệt từ Moderate giảm rõ rệt).

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy. → Vẫn bị nhầm hoàn toàn sang lớp liền kề.

Ma trận cho thấy sự cải thiện rõ nét ở khả năng phân biệt ranh giới giữa Moderate và Unhealthy for Sensitive Groups – hai lớp có số lượng nhầm lẫn lớn nhất trước đây. Khi dự báo 24 tiếng, mô hình ít đẩy Moderate lên mức cao hơn, đồng thời giảm tình trạng optimistic quá mức với Good. Kết quả này khá bất ngờ và tích cực, cho thấy CNN_LSTM có khả năng học tốt các mẫu hình dài hạn của dữ liệu AQI hơn là dự báo ngắn hạn. Trong ứng dụng thực tế tại TP.HCM, accuracy 88% và precision cao hơn ở lớp nhạy cảm sẽ giúp hệ thống cảnh báo đáng tin cậy hơn, hỗ trợ người dân và cơ quan quản lý ra quyết định kịp thời.

Kết quả dự đoán của mô hình Transformer

Bảng 7: Báo cáo phân loại chỉ số AQI mô hình Transformer 6 tiếng

6 tiếng	Precision	Recall	F1-score	support
Good	0.43	0.92	0.59	1153
Moderate	0.96	0.44	0.60	5146
Unhealthy	0.67	0.78	0.72	316
Unhealthy for Sensitive Groups	0.33	0.84	0.47	909
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.58	7522
Marco avg	0.48	0.60	0.48	7522
Weight avg	0.79	0.58	0.59	7522

Good (support = 1.153, chiếm ~15,3%): Precision = 0.43, Recall = 0.92, F1 = 0.59. Recall cực kỳ cao (0.92) cho thấy mô hình nhận diện gần như tất cả các mẫu thực sự thuộc mức Good. Tuy nhiên, precision rất thấp (chỉ 0.43) nghĩa là khi mô hình dự đoán Good thì chỉ có 43% là đúng – rất nhiều mẫu thuộc các lớp khác (chủ yếu Moderate) bị nhầm thành Good. Đây là dấu hiệu mô hình có xu hướng lạc quan.

Moderate (support = 5.146, chiếm ~68,4% – lớp chiếm ưu thế tuyệt đối): Precision = 0.96, Recall = 0.44, F1 = 0.60. Precision rất cao (0.96), cho thấy khi mô hình dự đoán Moderate thì độ tin cậy gần như tuyệt đối. Tuy nhiên, recall thấp chỉ 0.44 nghĩa là hơn một nửa số mẫu Moderate thực tế bị nhầm sang các lớp khác (chủ yếu Good và Unhealthy for Sensitive Groups). Lớp này có F1-score thấp hơn nhiều so với CNN_LSTM.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.67, Recall = 0.78, F1 = 0.72. Hiệu suất khá tốt và cân bằng ở mức trung bình-cao. Mô hình nhận diện tương đối tốt lớp Unhealthy, với recall cao hơn precision một chút.

Unhealthy for Sensitive Groups (support = 909, chiếm ~12,1%): Precision = 0.33, Recall = 0.84, F1 = 0.47. Đây là điểm yếu nghiêm trọng. Precision cực thấp (chỉ 0.33) cho thấy mô hình thường “quá mức” dự đoán lớp này. Dù recall cao (0.84), F1-score vẫn bị kéo xuống mạnh. Lớp này có hiệu suất kém nhất trong các lớp có support đáng kể.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Vẫn hoàn toàn không dự đoán đúng mẫu hiếm này, giống như tất cả các mô hình trước.

Accuracy = 0.58 (58%): Thấp hơn khá nhiều so với các mô hình CNN_LSTM (82–88%). Đây là mức accuracy kém nhất từ đầu đến nay.

Macro avg (0.48 | 0.60 | 0.48): Rất thấp, bị kéo mạnh bởi precision kém của Good, Moderate và Unhealthy for Sensitive Groups. Cho thấy mô hình xử lý kém các lớp thiểu số và không cân bằng giữa precision/recall.

Weighted avg (0.79 | 0.58 | 0.59): Cao hơn macro avg nhờ lớp Moderate chiếm đa số, nhưng vẫn thấp hơn nhiều so với CNN_LSTM.

Mô hình Transformer 6 tiếng cho thấy phong cách hoàn toàn khác biệt so với CNN_LSTM: nó cực kỳ lạc quan với lớp Good (recall cao, precision thấp) và bi quan với lớp Unhealthy for Sensitive Groups (precision rất thấp). Mặc dù precision của Moderate rất cao, nhưng recall thấp khiến mô hình bỏ lỡ quá nhiều mẫu Moderate thực tế. Accuracy chỉ 58% cho thấy Transformer chưa phù hợp tốt với bài toán dự báo AQI đa lớp trong khoảng thời gian ngắn (6 tiếng) trên tập dữ liệu này. Vấn đề mất cân bằng vẫn tồn tại, nhưng Transformer dường như phóng đại nó hơn qua việc tạo ra quá nhiều dự đoán sai ở lớp Good và Unhealthy for Sensitive Groups.



Hình 12: Kết quả dự đoán mô hình Transformer 6 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 1.059 (91,8%). Sai: 72 → Moderate, 22 → Unhealthy for Sensitive Groups. → Mô hình nhận diện rất tốt lớp Good (recall cao), chỉ nhầm một phần nhỏ sang các lớp khác.

Actual Moderate (5.146 mẫu): Dự đoán đúng: 2.267 (44,1%). Sai rất lớn: 1.379 → Good, 1.480 → Unhealthy for Sensitive Groups, 12 → Unhealthy, 8 → Very Unhealthy. → Đây là nguồn sai lớn nhất của ma trận. Gần 27% bị đẩy xuống Good và 29% bị đẩy lên Unhealthy for Sensitive Groups. Mô hình có xu hướng cực kỳ phân cực: hoặc dự đoán quá tốt (Good) hoặc quá xấu (Unhealthy for Sensitive Groups) với lớp Moderate.

Actual Unhealthy (316 mẫu): Dự đoán đúng: 245 (77,5%). Sai: 70 → Unhealthy for Sensitive Groups, 1 → Good. → Nhầm lẫn chủ yếu với lớp liền kề cao hơn.

Actual Unhealthy for Sensitive Groups (909 mẫu): Dự đoán đúng: 767 (84,4%). Sai: 107 → Unhealthy, 27 → Moderate, 4 → Good, 4 → Very Unhealthy. → Recall cao, nhưng lớp này nhận rất nhiều mẫu từ Moderate (1.480 mẫu), dẫn đến precision thấp.

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy. → Bị nhầm sang lớp liền kề.

Bảng 8: Báo cáo phân loại chỉ số AQI mô hình Transformer 12 tiếng

12 tiếng	Precision	Recall	F1-score	support
Good	0.31	0.96	0.47	1153
Moderate	0.96	0.30	0.46	5146
Unhealthy	0.58	0.80	0.67	316
Unhealthy for Sensitive Groups	0.37	0.75	0.49	908
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.48	7524
Marco avg	0.44	0.56	0.42	7524
Weight avg	0.77	0.48	0.47	7524

Good (support = 1.153, chiếm ~15,3%): Precision = 0.31, Recall = 0.96, F1 = 0.47. Recall cực cao (0.96) cho thấy mô hình gần như bắt được hầu hết các mẫu thực sự là Good. Tuy nhiên, precision rất thấp (chỉ 0.31) nghĩa là khi mô hình dự đoán Good thì chỉ khoảng 31% là đúng. Có rất nhiều mẫu từ lớp Moderate bị nhầm thành Good.

Moderate (support = 5.146, chiếm ~68,4% – lớp chiếm ưu thế tuyệt đối): Precision = 0.96, Recall = 0.30, F1 = 0.46. Precision vẫn rất cao (0.96), nhưng recall giảm mạnh xuống chỉ 0.30. Mô hình bỏ sót tới 70% số mẫu Moderate thực tế. Đây là điểm yếu nghiêm trọng của lớp chiếm đa số.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.58, Recall = 0.80, F1 = 0.67. Hiệu suất khá cân bằng ở mức trung bình. Recall cao cho thấy mô hình nhận diện tốt các trường hợp Unhealthy thực tế.

Unhealthy for Sensitive Groups (support = 908, chiếm ~12,1%): Precision = 0.37, Recall = 0.75, F1 = 0.49. Precision thấp (0.37) dù recall ở mức khá. Mô hình vẫn dự đoán lớp này quá nhiều (nhiều false positive), dẫn đến F1-score thấp.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Vẫn không dự đoán đúng mẫu hiếm này.

Accuracy = 0.48 (48%): Thấp hơn cả phiên bản 6 tiếng (58%). Hiệu suất tổng thể giảm rõ rệt khi dự báo dài hơn.

Macro avg (0.44 | 0.56 | 0.42): Rất thấp, cho thấy mô hình kém cân bằng và xử lý kém các lớp.

Weighted avg (0.77 | 0.48 | 0.47): Thấp hơn nhiều so với CNN_LSTM, phản ánh hiệu suất thực tế kém.

Mô hình Transformer 12 tiếng tiếp tục duy trì phong cách “phân cực” và lạc quan mạnh mẽ. Precision của Good và Unhealthy for Sensitive Groups vẫn rất thấp, trong khi recall của Moderate giảm sâu. Accuracy chỉ còn 48% cho thấy Transformer gặp nhiều khó khăn hơn khi dự báo xa 12 tiếng. So với CNN_LSTM (accuracy 82% ở cùng khoảng thời gian), Transformer kém hơn rất nhiều. Trong thực tế tại TP.HCM, precision thấp của Good (0.31) và Unhealthy for Sensitive Groups (0.37) sẽ gây ra vô số cảnh báo sai, làm giảm nghiêm trọng độ tin cậy của hệ thống.



Hình 13: Kết quả dự đoán mô hình Transformer 12 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 1.111 (96,4%). Sai: 24 → Moderate, 18 → Unhealthy for Sensitive Groups. → Recall cực cao, mô hình nhận diện gần như toàn bộ lớp Good.

Actual Moderate (5.146 mẫu): Dự đoán đúng: 1.539 (29,9%). Sai rất lớn: 2.490 → Good, 1.094 → Unhealthy for Sensitive Groups, 22 → Unhealthy, 1 → Very Unhealthy. → Đây là nguồn sai lớn nhất. Gần 48% Moderate bị nhầm thành Good (quá lạc quan) và 21% bị nhầm thành Unhealthy for Sensitive Groups (quá bi quan). Mô hình tiếp tục “kéo mạnh” lớp Moderate về hai cực.

Actual Unhealthy (316 mẫu): Dự đoán đúng: 253 (80,1%). Sai: 59 → Unhealthy for Sensitive Groups, 1 → Good, 1 → Moderate, 2 → Very Unhealthy. → Nhầm lẫn chủ yếu với lớp liền kề cao hơn.

Actual Unhealthy for Sensitive Groups (908 mẫu): Dự đoán đúng: 683 (75,2%). Sai: 163 → Unhealthy, 40 → Moderate, 20 → Good, 2 → Very Unhealthy. → Nhận nhiều mẫu từ Moderate (1.094), dẫn đến precision thấp.

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy.

Ma trận cho thấy Transformer 12 tiếng càng thể hiện rõ xu hướng lạc quan mạnh với Good và tạo ra quá nhiều dự đoán sai cho Unhealthy for Sensitive Groups, chủ yếu lấy từ lớp Moderate. So với phiên bản 6 tiếng, recall của Moderate giảm sâu hơn, dẫn đến accuracy tổng thể giảm. Mô hình vẫn nắm được thứ tự các lớp AQI nhưng không nắm được ranh giới mịn giữa chúng.

Bảng 9: Báo cáo phân loại chỉ số AQI mô hình Transformer 24 tiếng

24 tiếng	Precision	Recall	F1-score	support
Good	0.40	0.95	0.56	1153
Moderate	0.96	0.46	0.62	5145
Unhealthy	0.76	0.70	0.73	316
Unhealthy for Sensitive Groups	0.38	0.85	0.53	907
Very Unhealthy	0.00	0.00	0.00	1
Accuracy			0.59	7522
Marco avg	0.50	0.59	0.49	7522
Weight avg	0.79	0.59	0.61	7522

Good (support = 1.153, chiếm ~15,3%): Precision = 0.40, Recall = 0.95, F1 = 0.56. Recall cực cao (0.95) cho thấy mô hình gần như bắt được toàn bộ các mẫu thực sự là Good. Tuy nhiên, precision chỉ 0.40 nghĩa là khi mô hình dự đoán Good thì chỉ 40% là đúng. Vẫn còn rất nhiều mẫu từ lớp Moderate bị nhầm thành Good.

Moderate (support = 5.145, chiếm ~68,4% – lớp chiếm ưu thế tuyệt đối): Precision = 0.96, Recall = 0.46, F1 = 0.62. Precision rất cao (0.96), nhưng recall chỉ 0.46. Mô hình bỏ sót hơn một nửa số mẫu Moderate thực tế. F1-score cải thiện nhẹ so với 12 tiếng nhưng vẫn thấp.

Unhealthy (support = 316, chiếm ~4,2%): Precision = 0.76, Recall = 0.70, F1 = 0.73. Đây là lớp có hiệu suất tốt nhất trong mô hình. Cả precision và recall đều ở mức khá cao và cân bằng.

Unhealthy for Sensitive Groups (support = 907, chiếm ~12,1%): Precision = 0.38, Recall = 0.85, F1 = 0.53. Precision thấp (0.38) dù recall khá cao. Mô hình vẫn dự đoán lớp này quá nhiều (nhiều false positive), dẫn đến F1-score thấp.


Very Unhealthy (support = 1, chiếm 0,013%): Precision = 0.00, Recall = 0.00, F1 = 0.00. Vẫn không dự đoán đúng mẫu hiếm này.

Accuracy = 0.59 (59%): Tăng nhẹ so với 48% ở 12 tiếng nhưng vẫn thấp hơn nhiều so với CNN_LSTM (88% ở cùng 24 tiếng).

Macro avg (0.50 | 0.59 | 0.49): Thấp, cho thấy mô hình vẫn kém cân bằng giữa các lớp.

Weighted avg (0.79 | 0.59 | 0.61): Cao hơn macro avg nhờ lớp Moderate chiếm đa số, nhưng vẫn ở mức trung bình.

Mô hình Transformer 24 tiếng vẫn giữ phong cách như hai phiên bản trước. Precision của Good và Unhealthy for Sensitive Groups tiếp tục thấp, trong khi recall của Moderate chỉ 0.46. Accuracy chỉ 59% cho thấy Transformer gặp khó khăn lớn khi dự báo dài hạn. So với CNN_LSTM 24 tiếng (accuracy 88%, F1 macro 0.65), Transformer kém hơn hẳn. Trong thực tế tại TP.HCM, precision thấp của Good (0.40) và Unhealthy for Sensitive Groups (0.38) sẽ gây ra rất nhiều cảnh báo sai, làm giảm đáng kể độ tin cậy của hệ thống.



Hình 14: Kết quả dự đoán mô hình Transformer 24 tiếng

Actual Good (1.153 mẫu): Dự đoán đúng: 1.095 (95,0%). Sai: 45 → Moderate, 13 → Unhealthy for Sensitive Groups. → Recall cực cao, mô hình nhận diện rất tốt lớp Good.

Actual Moderate (5.145 mẫu): Dự đoán đúng: 2.379 (46,2%). Sai rất lớn: 1.628 → Good, 1.126 → Unhealthy for Sensitive Groups, 12 → Very Unhealthy, 2 → Unhealthy. → Đây là nguồn sai lớn nhất. Khoảng 32% Moderate bị nhầm thành Good (quá lạc quan) và 22% bị nhầm thành Unhealthy for Sensitive Groups (quá bi quan). Mô hình tiếp tục “kéo mạnh” lớp Moderate về hai cực.

Actual Unhealthy (316 mẫu): Dự đoán đúng: 222 (70,3%). Sai: 88 → Unhealthy for Sensitive Groups, 3 → Very Unhealthy, 2 → Moderate, 1 → Good. → Nhầm lẫn chủ yếu với lớp liền kề cao hơn.

Actual Unhealthy for Sensitive Groups (907 mẫu): Dự đoán đúng: 767 (84,6%). Sai: 71 → Unhealthy, 58 → Moderate, 6 → Good, 5 → Very Unhealthy. → Nhận nhiều mẫu từ Moderate (1.126), dẫn đến precision thấp.

Actual Very Unhealthy (1 mẫu): Dự đoán đúng: 0. Sai: 1 → Unhealthy.

Ma trận cho thấy Transformer 24 tiếng vẫn giữ xu hướng lạc quan mạnh với Good và tạo ra quá nhiều dự đoán sai cho Unhealthy for Sensitive Groups (chủ yếu lấy từ Moderate). So với phiên bản 12 tiếng, recall của Moderate tăng nhẹ nhưng vẫn thấp, dẫn đến accuracy tổng thể chỉ 59%. Mô hình nắm được thứ tự các lớp AQI nhưng không nắm chắc ranh giới mịn giữa chúng.

4.4.2 Phân tích và đánh giá

Bảng báo cáo phân loại và ma trận nhầm lẫn được sử dụng để đánh giá hiệu suất của hai kiến trúc mô hình: CNN-LSTM và Transformer. Các mô hình được huấn luyện và kiểm tra với ba horizon thời gian dự đoán là 6 tiếng, 12 tiếng và 24 tiếng.

Trong đó lớp “Moderate” chiếm tỷ lệ lớn nhất, trong khi lớp “Very Unhealthy” chỉ có 1 mẫu.

Mô hình CNN-LSTM đạt hiệu suất tốt nhất ở horizon 12 tiếng với độ chính xác tổng thể (Accuracy) là 88% và F1-score weighted average đạt 0.88. Macro average F1-score ở mức 0.65 cho thấy khả năng cân bằng tương đối giữa các lớp.

Tại horizon 6 tiếng, mô hình cũng đạt kết quả khá ổn định với Accuracy 83%. Tuy nhiên, khi tăng horizon lên 24 tiếng, hiệu suất giảm rõ rệt (Accuracy chỉ còn 48%), cho thấy mô hình gặp khó khăn trong việc nắm bắt mối quan hệ dài hạn.

Mô hình Transformer cho kết quả không đồng đều theo các horizon thời gian. Ở horizon 6 tiếng, mô hình đạt Accuracy 82%, gần tương đương với CNN-LSTM.

Đáng chú ý, tại horizon 12 tiếng, hiệu suất của Transformer giảm mạnh với Accuracy chỉ đạt 58% và Macro average F1-score là 0.48. Ngược lại, ở horizon 24 tiếng, Transformer cho kết quả tốt hơn CNN-LSTM với Accuracy 59%, cho thấy ưu thế của cơ chế attention trong việc xử lý chuỗi dài.

Bảng 10: So sánh hiệu suất giữa hai mô hình

Thời gian dự báo	Mô hình	Accuracy	Macro Avg F1-score	Weighted Avg F1-score	Precision Good	Precision Unhealthy for Sensitive Groups	Recall Moderate	Nhận xét
6 tiếng	CNN_LSTM	0.83	0.62	0.84	0.71	0.58	0.83	Tốt nhất trong CNN_LSTM
6 tiếng	Transformer	0.58	0.48	0.59	0.43	0.33	0.44	Kém
12 tiếng	CNN_LSTM	0.82	0.61	0.82	0.68	0.56	0.81	Giảm nhẹ so với 6 tiếng
12 tiếng	Transformer	0.48	0.42	0.47	0.31	0.37	0.30	Kém nhất
24 tiếng	CNN_LSTM	0.88	0.65	0.88	0.81	0.72	0.92	Tốt nhất trong tất cả
24 tiếng	Transformer	0.59	0.49	0.61	0.40	0.38	0.46	Cải thiện nhẹ nhưng vẫn kém

Từ bảng tổng hợp trên, có thể rút ra một số nhận xét quan trọng:

CNN_LSTM vượt trội rõ rệt so với Transformer ở tất cả các khoảng thời gian dự báo. Accuracy của CNN_LSTM dao động từ 82% – 88%, trong khi Transformer chỉ đạt 48% – 59%. Macro F1-score (chỉ số quan trọng đánh giá khả năng xử lý các lớp thiểu số) của CNN_LSTM cũng cao hơn đáng kể (0.61 – 0.65 so với 0.42 – 0.49).

Với CNN_LSTM: Hiệu suất có xu hướng cải thiện khi thời gian dự báo tăng (từ 83% ở 6 tiếng lên 88% ở 24 tiếng). Điều này cho thấy mô hình học tốt các xu hướng dài hạn và

chu kỳ của dữ liệu AQI (như biến động ngày/đêm hoặc ảnh hưởng thời tiết kéo dài). Xử lý tốt lớp chiếm ưu thế (Moderate) với precision và recall cao, đồng thời giảm được nhầm lẫn giữa các lớp liên kề khi dự báo dài hạn. Precision của lớp “Unhealthy for Sensitive Groups” cũng cải thiện rõ (từ 0.58 lên 0.72), rất quan trọng cho cảnh báo sức khỏe cộng đồng.

Với Transformer: Hiệu suất giảm mạnh ở 12 tiếng rồi phục hồi nhẹ ở 24 tiếng, nhưng vẫn ở mức thấp. Transformer thể hiện rõ xu hướng recall Good rất cao nhưng precision thấp và bỏ sót nhiều mẫu Moderate (recall Moderate chỉ 0.30 – 0.46). Có precision cao ở Moderate khi dự đoán, nhưng recall quá thấp dẫn đến bỏ sót nhiều trường hợp thực tế. Mô hình thường “kéo” Moderate về hai cực (Good hoặc Unhealthy for Sensitive Groups), gây ra nhiều dự đoán sai ở lớp người nhạy cảm thời tiết.

Tổng kết Chương 4

Kết quả thực nghiệm đã khẳng định tính khả thi và độ tin cậy của hệ thống dự báo AQI tại TP. Hồ Chí Minh. Với cột mốc quan trọng là hệ số R^2 vượt ngưỡng 0.90 cho tầm nhìn 24 giờ, nghiên cứu đã chứng minh rằng các mô hình học sâu không chỉ dừng lại ở lý thuyết mà đã sẵn sàng ứng dụng thực tiễn. Sức mạnh tổng hợp từ khả năng trích xuất đặc trưng của CNN, khả năng ghi nhớ chuỗi của LSTM và cơ chế tự chú ý của Transformer đã tạo ra một giải pháp dự báo chính xác, minh bạch, hỗ trợ đắc lực cho công tác quản lý môi trường đô thị.

CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ

5.1. Kết luận

Nghiên cứu đã xây dựng và đánh giá một hệ thống dự báo chất lượng không khí tại Thành phố Hồ Chí Minh dựa trên dữ liệu khí tượng và nồng độ bụi mịn $PM_{2.5}$ trong giai đoạn 2018–2023. Thay vì chỉ tập trung vào dự báo một thông số riêng lẻ, đề tài đã mở rộng bài toán sang dự báo Chỉ số Chất lượng Không khí (AQI) dưới cả hai dạng: hồi quy (giá trị số) và phân loại (mức độ cảnh báo sức khỏe). Cách tiếp cận này giúp nâng cao giá trị ứng dụng thực tiễn của mô hình trong bối cảnh đô thị hóa nhanh và nhu cầu cảnh báo ô nhiễm ngày càng cao.

Quy trình nghiên cứu được triển khai một cách hệ thống, bao gồm các bước từ thu thập dữ liệu, tiền xử lý, xây dựng đặc trưng, thiết lập bài toán, huấn luyện mô hình cho đến đánh giá và giải thích kết quả. Trong đó, các kỹ thuật tiền xử lý như nội suy dữ liệu, chuẩn hóa Min-Max và mã hóa chu kỳ thời gian bằng hàm lượng giác đã góp phần cải thiện đáng kể khả năng học của mô hình.

Kết quả thực nghiệm cho thấy các mô hình học sâu, đặc biệt là CNN, đạt hiệu suất cao trong bài toán dự báo $PM_{2.5}$. Tại mốc dự báo 24 giờ, mô hình CNN đạt hệ số xác định $R^2 = 0.9005$, cho thấy khả năng giải thích tốt sự biến động của dữ liệu và nắm bắt hiệu quả các đặc trưng chu kỳ theo thời gian. Đồng thời, các mô hình kết hợp như LSTM_CNN cũng thể hiện tiềm năng trong việc khai thác phụ thuộc dài hạn của chuỗi dữ liệu.

Ở bài toán phân loại AQI, các mô hình đã đạt độ chính xác cao trong việc nhận diện các mức độ chất lượng không khí, đặc biệt là khả năng phát hiện các trạng thái ô nhiễm nghiêm trọng (Unhealthy). Việc tối ưu chỉ số Recall cho các lớp nguy hiểm cho thấy mô hình có khả năng hỗ trợ hiệu quả trong các hệ thống cảnh báo sớm.

Ngoài ra, nghiên cứu cũng chứng minh vai trò quan trọng của các đặc trưng khí tượng như bức xạ UVB trong việc cải thiện độ chính xác dự báo, đặc biệt trong các khung giờ có hoạt động quang hóa mạnh. Điều này cho thấy việc tích hợp đa nguồn dữ liệu là hướng đi cần thiết trong các bài toán môi trường phức tạp.

Tổng thể, kết quả đạt được đã khẳng định tính khả thi của việc ứng dụng các mô hình học máy và học sâu trong dự báo chất lượng không khí tại Việt Nam, đồng thời mở ra tiềm năng triển khai trong các hệ thống hỗ trợ quản lý môi trường đô thị.

5.2. Hạn chế của nghiên cứu

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế nhất định:

- **Hạn chế về dữ liệu không gian:** Dữ liệu sử dụng chủ yếu được thu thập từ một số trạm quan trắc cố định, chưa phản ánh đầy đủ sự phân bố không gian của ô nhiễm trong toàn thành phố.
- **Chưa khai thác dữ liệu ngoại sinh:** Các yếu tố như mật độ giao thông, hoạt động công nghiệp, hoặc dữ liệu vệ tinh chưa được tích hợp, trong khi đây là những nguồn thông tin có ảnh hưởng lớn đến chất lượng không khí.
- **Giới hạn về mô hình:** Mặc dù đã thử nghiệm nhiều kiến trúc, nghiên cứu chưa khai thác sâu các mô hình tiên tiến như Transformer đa biến hoặc Graph Neural Networks (GNN) trong việc học quan hệ không gian – thời gian.
- **Xử lý sự kiện bất thường còn hạn chế:** Các hiện tượng đột biến như cháy rừng, đốt rơm rạ hoặc điều kiện thời tiết cực đoan vẫn gây sai số lớn cho mô hình.

5.3. Hướng phát triển trong tương lai

Dựa trên các kết quả đạt được và những hạn chế đã nêu, một số hướng phát triển tiềm năng được đề xuất như sau:

- **Tích hợp dữ liệu đa nguồn:** Kết hợp dữ liệu từ nhiều trạm quan trắc, dữ liệu vệ tinh và dữ liệu giao thông để nâng cao khả năng phản ánh thực tế của mô hình.
- **Ứng dụng mô hình học sâu tiên tiến:** Triển khai các kiến trúc như Transformer hoặc Graph Neural Networks (GNN) để khai thác tốt hơn các mối quan hệ không gian và thời gian phức tạp.
- **Phát triển hệ thống dự báo thời gian thực:** Xây dựng pipeline xử lý dữ liệu và dự báo liên tục nhằm phục vụ các hệ thống cảnh báo ô nhiễm theo thời gian thực.
- **Kết hợp mô hình giải thích:** Mở rộng việc sử dụng các phương pháp như SHAP và LIME để tăng tính minh bạch và khả năng giải thích của mô hình trong các ứng dụng thực tế.
- **Triển khai ứng dụng thực tế:** Phát triển các nền tảng web hoặc mobile giúp người dân dễ dàng tiếp cận thông tin AQI và nhận cảnh báo sớm về chất lượng không khí.

TÀI LIỆU THAM KHẢO

- [1] T. N. Đăng, N. N. N. Thanh and V. A. Tuấn, "Tác động của bụi mịn do giao thông đến tỷ lệ tử vong tại TP. Hồ Chí Minh," *Bản B của Tạp chí Khoa học và Công nghệ Việt Nam*, p. 67(12), 2025.
- [2] T. Ho, C. Van Dang, T. Pham, H. Ngo and S. Wangwongwatana, "Assessment of the association between PM2. 5 concentration and hospital admissions for pediatric asthma in Ho Chi Minh City, Viet Nam," *Hygiene and Environmental Health Advances*, p. 100097, 2024.
- [3] S. A. Pozza, E. P. Lima, T. T. Comin, M. L. Gimenes and J. R. Coury, "Time series analysis of PM2. 5 and PM10– 2.5 mass concentration in the city of Sao Carlos, Brazil," *International Journal of Environment and Pollution*, pp. 41(1-2), 90-108., 2010.
- [4] A. Jebamalar, "PM2. 5 prediction using machine learning hybrid model for smart health," *International Journal of Engineering and Advanced Technology*., 2019.
- [5] A. S. Mohan and L. Abraham, "An ensemble deep learning model for forecasting hourly PM2. 5 concentrations," *IETE Journal of Research*, pp. 69(10), 6832-6845., 2023.
- [6] W. Bank, "Institute for Health Metrics and Evaluation," in *The Cost of Air Pollution: Strengthening the Economic Case for Action*, World Bank, Washington, DC, 2016.
- [7] H. E. Hesketh, Introduction to Air Pollution,, Introduction to Air Pollution, in: Wang, L.K., Pereira, N.C. (Eds.), 1979, p. pp. 3–39.
- [8] WHO., "WHO," 31 1 2024. [Online]. Available: <https://www.who.int/data/gho/data/themes/air-pollution/who-air-quality-database..>
- [9] S. H. Dwyer, J. Graff Zivin, M. Neidell and Aguilar-Gimez, "This is air: The “nonhealth” effects of air pollution." *Annual Review of Resource Economics*, 2022, pp. 403-425.
- [10] Y. F. Xing, Y. H. Xu, M. H. Shi and Y. X. Lian, ""The impact of PM2. 5 on the human respiratory system.," in *Journal of thoracic disease E69*, 2016.
- [11] T. Li, R. Hu, Z. Chen, Q. Li, S. Huang, Z. Zhu and L. F. Zhou, "Fine particulate matter (PM2. 5): The culprit for chronic lung diseases in China," *Chronic diseases and translational medicine*, pp. 176-186, 2018.
- [12] J. Lelieveld, J. S. Evans, M. Fnais, D. Giannadaki and A. Pozzer, "The contribution of outdoor air pollution sources to premature mortality on a global scale," *Nature*, pp. 367-371, 2015.
- [13] "WHO," 2 May 2018. [Online]. Available: <https://www.who.int/vietnam/vi/news/detail/02-05-2018-more-than-60-000-deaths-in-viet-nam-each-year-linked-to-air-pollution>.
- [14] T. Hien, N. Chi, N. Nguyen, L. Vinh, N. Takenaka and D. Huy, "Current Status of Fine Particulate Matter (PM2.5) in Vietnam’s Most Populous City, Ho Chi Minh City," *Aerosol and Air Quality Research*, pp. 2239-2251, 2019.
- [15] L. Breiman, "Random forests," *Machine Learning*, pp. 45(1), 5–32, 2001.
- [16] H. Park, K. Kim and D. k. Lee, "Prediction of severe drought area based on random forest: Using satellite image and topography data," *Water*, pp. 11(4), 705, 2019.
- [17] J. M. Breiman, "Bagging predictors.," *Machine Learning*, pp. 24(2), 123–140, 1996.
- [18] H. Druker, C. J. Burges, L. Kaufman, A. J. Smola and V. N. Vapnik, "Support vector regression machines. In *Advances in Neural Information Processing Systems*," *MIT Press*, p. 155–161, 1997.

- [19] Y. Bao, M. Hayashida and T. Akutsu, "LBSizeClev: Improved support vector machines (SVM)-based predictions of Dicer cleavage sites using loop/bulge length.," *BMC Bioinformatics*, pp. 17(1), 487, 2016.
- [20] J. A. K. Suykens and J. Vandewalle, "Least square support vector machine classifiers," *Neural Processing Letters*, pp. 9(3), 293–300, 1999.
- [21] R. A. Berk, "Statistical learning from a regression perspective," *New York: Springer*, p. Vol. 14, 2008.
- [22] C. J. Huang and P. H. Kuo, "A deep CNN-LSTM model for particulate matter (PM2. 5) forecasting in smart cities," in *Sensors*, 2018, pp. 18(7), 2220..
- [23] P. Pan, A. S. Malarvizhi and C. Yang, "Data Augmentation Strategies for Improved PM2. 5 Forecasting Using Transformer Architectures," *Atmosphere*, pp. 16(2), 127., 2025.